Facultad Politécnica
Universidad Nacional de Asunción

FP-UNA - CONSTRUYENDO EL FUTURO

DISTRIBUCIONES MUESTRALES

Material de Lectura

Este material de lectura tiene la finalidad desarrollar la clase de Muestras Aleatorias y Distribuciones de Muestreo, contiene información básica y desarrollo de ejemplos particulares por cada distribución de probabilidad. La misma debe ser complementada con los textos disponibles en el programa de estudios de la asignatura

Yda

Índice

1 Introducción 3
2 Conceptos Básicos 3
2.1 INFERENCIA ESTADÍSTICA 3
2.2 POBLACIÓN (N) 3
2.3 MUESTRA (N): 3
2.4 MUESTREO 3
2.5 PARÁMETRO 4
2.6 ESTADÍSTICO 4
3 Distribuciones muestrales 4
3.1 DISTRIBUCIÓN MUESTRAL DE MEDIAS 4
3.2 DISTRIBUCIÓN MUESTRAL DE DIFERENCIA DE MEDIAS 7
3.3 DISTRIBUCIÓN MUESTRAL DE LA PROPORCIÓN 8
3.4 DISTRIBUCIONES MUESTRALES PARA DIFERENCIA DE PROPORCIONES 10
4 Bibliografía 12

1 Introducción

Para la estadística inferencial es muy importante el estudio del comportamiento de las variables, para ello es necesario poder encontrar estadísticos que puedan ser utilizados como parámetros de estimación. Según Canavos (1995), si se emplea una estadística T para estimar un parámetro desconocido θ, entonces T recibe el nombre de estimador de θ y el valor específico de t como un resultado de los datos muestrales recibe el nombre de estimación de θ. Un parámetro es una constante pero un estadístico es una variable aleatoria.
Para el estudio de una población se necesita conocer cierta información sobre ella, y si esta es muy extensa, dificulta estudiarlo en su totalidad, de allí la importancia de tener técnicas que ayuden a medir esta población de interés. Para una inferencia convincente y eficiente se utiliza el muestreo.
Por qué muestrear?
Porque a través de él podemos hacer análisis de situaciones de una empresa o de algún campo de la sociedad.

2 Conceptos Básicos

Recordemos que la probabilidad es la herramienta matemática que solidifica en gran parte la estadística inferencial y por ello es importante que recordemos conceptos básicos y detallemos un poco aquellas definiciones que hacen al trabajo inferencial. La idea es que podamos trabajar con muestras y sobre los resultados obtenidos en ellas, podamos concluir algo acerca de la población que es objeto de interés.
Nuestro principal propósito al seleccionar muestras aleatorias consiste en obtener información acerca de los parámetros desconocidos de la población.

2.1 Inferencia estadística

Es el proceso de sacar conclusiones de la población basados en la información de una muestra de esa población

2.2 Población (N)

La totalidad de observaciones (sobre cualquier cuestión de interés) que nos importan, ya sean de número finito o infinito, constituye lo que se llama *población*

2.3 Muestra (n):

Parte de la población, subconjunto de la población. Grupo de individuos que son seleccionados de la población.

2.4 Muestreo

Es el proceso por el cual se extrae la muestra de la población. El muestreo puede ser probabilístico o no probabilístico. Nos ocuparemos del muestreo probabilístico, puesto que este procedimiento nos permite trabajar en la muestra e inferir en la población
"El muestreo aleatorio simple selecciona muestras mediante métodos que permiten que cada posible muestra tenga una igual probabilidad de ser seleccionada y que cada elemento de la población total tenga una oportunidad igual de ser incluido en la muestra." Levin y Rubin (2010)
Desde un punto de vista teórico, el concepto de muestreo es fundamental para la Inferencia Estadística. El hecho de que las muestras no sean exactamente representativas de las poblaciones significa que las inferencias presentan cierto margen de incertidumbre. Para cuantificarlo y definir técnicas inferenciales es necesario conocer cómo se comportan los estadísticos obtenidos en las muestras,

esto es, cómo son las distribuciones muestrales de los estadísticos habitualmente utilizados para la inferencia.

2.5 Parámetro

Es una medida de resumen de una característica observada en la población.

- El promedio de edad de todos los egresados de Universidades del Paraguay en cierto periodo de años (μ)
- La variabilidad de la edad de estos estudiantes egresados con respecto a su media (σ^2)
- La proporción de mujeres egresadas en la población mencionada (P)

Notemos que μ, $\boldsymbol{\sigma^2}$, $\boldsymbol{P}$, son medidas de resúmenes de ciertas características de interés de la población estudiada, son por lo tanto *parámetros.*

2.6 Estadístico

Es una medida de resumen de una característica observada en la muestra. El valor de la estadística se conoce cuando tomamos una muestra, pero varía de muestra en muestra

Tomamos una muestra de 20 egresados de Universidades de Paraguay en el periodo de 2010 a 2013. De la muestra calculamos:

- El promedio de edad de los egresados $(\bar{x})$
- La variabilidad de la edad de los egresados con respecto al promedio (S^2)
- La proporción de mujeres que egresan (p)

Notemos que $\boldsymbol{\bar{x}}$, $\boldsymbol{s^2}$ ***y p*** son medidas calculadas con los datos de la muestra, por lo tanto son *estadísticos*

Como los parámetros son generalmente desconocidos, el cálculo de los estadísticos muestrales nos permite determinar estimaciones de los verdaderos valores de las medidas poblaciones

3 Distribuciones muestrales

La distribución de probabilidad de un *estadístico* se denomina *Distribución muestral*. Una estadística muestral proveniente de una muestra aleatoria simple tiene un patrón de comportamiento (predecible) en repetidas muestras. Este patrón es llamado la distribución muestral de la estadística (media, desviación típica, proporción etc). Si conocemos la distribución muestral podemos hacer inferencia.

3.1 Distribución muestral de medias

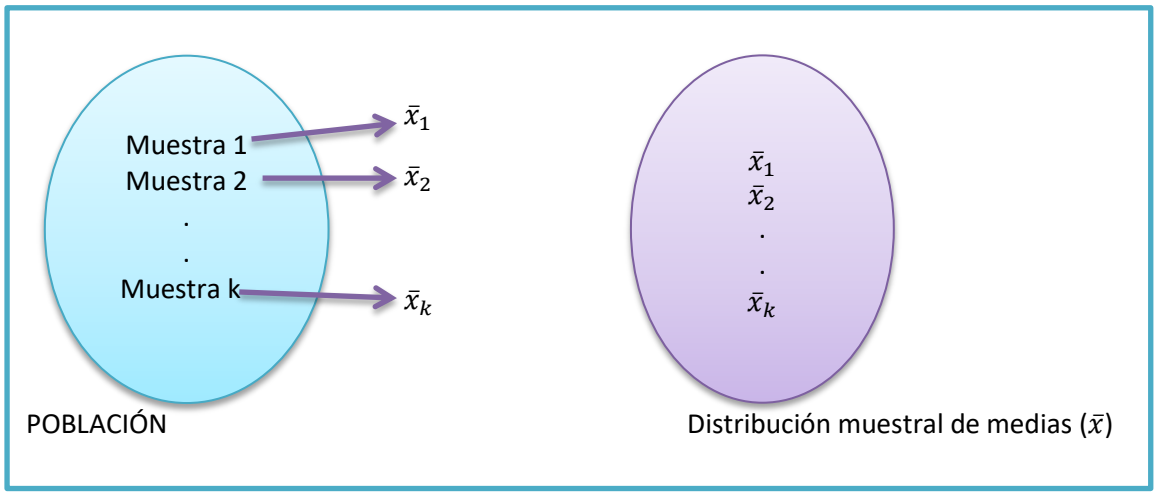

Tiene como objetivo principal estimar la media de la población a partir de la distribución que siguen las medias de las diferentes muestras obtenidas.
Supongamos que tomamos varias muestras de una población, los promedios para cada muestra no necesariamente serían iguales, y lo más probable es que varíen de una muestra a otra.
Imaginemos que cada una de las muestras tomadas consta de 10 mujeres de 25 años de edad residentes en todo el Paraguay. Al calcular la estatura media y la desviación estándar correspondiente a cada una de estas muestras, veríamos que la media $(\bar{x})$ y la desviación (s) de cada muestra serían diferentes.
Cada una de las medias que hemos calculado forma el conjunto de todas las medias muestrales que recibe el nombre de *distribución muestral de la media*. La media y la desviación estándar lo simbolizaremos de la siguiente forma

$\mu_{\bar{x}}$ = media de la distribución muestral de medias
$\sigma_{\bar{x}}$ = desviación estándar de la distribución muestral = error muestral

$$\boldsymbol{\mu_{\bar{x}}} = \frac{\bar{x}_1+\bar{x}_2+\bar{x}_3+\ldots+\bar{x}_n}{n} \qquad \boldsymbol{\mu_{\bar{x}}} = \frac{\sum_{i=1}^{n}\bar{x}_i}{n}$$

$$\boldsymbol{\sigma_{\bar{x}}} = \sqrt{\frac{\sum_{i=1}^{n}(\bar{x}_i-\mu_{\bar{x}})}{n}} \qquad \boldsymbol{\sigma_{\bar{x}}} = \frac{\sigma}{\sqrt{n}}$$

Observemos que la distribución de muestreo de una media de una población normalmente distribuida tiene propiedades importantes a saber:

- La distribución de muestreo tiene una media igual a la media de la población, $\boldsymbol{\mu_{\bar{x}} = \mu}$
- La distribución de muestreo tiene una desviación estándar (un error estándar) igual a la desviación estándar de la población dividida entre la raíz cuadrada del tamaño de la muestra (si la población es infinita o el muestreo se realiza con reemplazo)

  $$\boldsymbol{\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}}$$
- Si la población es finita o el muestreo se realiza sin reemplazo, el error estándar toma la forma de

  $\boldsymbol{\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}}.\sqrt{\frac{N-n}{N-1}}}$, donde N es el tamaño de la población y n es el tamaño de la muestra
- Convengamos que cuando trabajamos con muestras de tamaño mayor a 30 o bien muestras de cualquier tamaño de una distribución normal, la distribución muestral de medias tiende a una distribución normal con $\mu = \mu_{\bar{x}}$ y $\sigma = \sigma_{\bar{x}}$, entonces la fórmula que utilizaremos para la estandarización es:

$\boldsymbol{z = \frac{\bar{x}-\mu_{\bar{x}}}{\sigma_{\bar{x}}}}$, o su equivalente

$\boldsymbol{z = \frac{\bar{x}-\mu_{\bar{x}}}{\frac{\sigma}{\sqrt{n}}}}$ para muestreo con reemplazo y poblaciones infinitas

$\boldsymbol{z = \frac{\bar{x}-\mu_{\bar{x}}}{\frac{\sigma}{\sqrt{n}}.\sqrt{\frac{N-n}{N-1}}}}$, para muestreo sin reemplazo y poblaciones finitas

Ejemplo 1: La vida media de una máquina para elaborar pan es de 7 años, con una desviación estándar de 1 año. Suponga que la vida de estas máquinas sigue aproximadamente una distribución normal, calcule

a) La probabilidad de que la vida media de una muestra aleatoria de 9 de éstas máquinas caiga entre 6.4 y 7.2 años
b) El valor de x a la derecha del cual caería 15% de las medias calculadas de muestras aleatorias de tamaño 9

Solución

Los datos que inicialmente nos da el problema corresponden a la población, porque nos habla en general, es decir, tenemos:

$\mu = 7$ y $\sigma = 1$ (media y desviación típica poblacional)

a) Se toma una muestra aleatoria de tamaño 9, es decir:
$n = 9$ y con este dato nos pregunta, cuál será la probabilidad de que la media muestral ($\bar{x}$) esté entre 6.4 y 7.2
$P(6.4 < \bar{x} < 7.2)$= ?
Pasamos a tipificar ambos valores utilizando la siguiente fórmula porque la población es infinita $\boldsymbol{z} = \frac{\bar{\boldsymbol{x}} - \boldsymbol{\mu}_{\bar{\boldsymbol{x}}}}{\frac{\boldsymbol{\sigma}}{\sqrt{\boldsymbol{n}}}}$

$z_1 = \frac{6.4-7}{\frac{1}{\sqrt{9}}} = -1.8$ y $z_2 = \frac{7.2-7}{\frac{1}{\sqrt{9}}} = 0.6$

$P(-1.8 < Z < 0.6) = 0.4641 + 0.2257 = 0.6898$

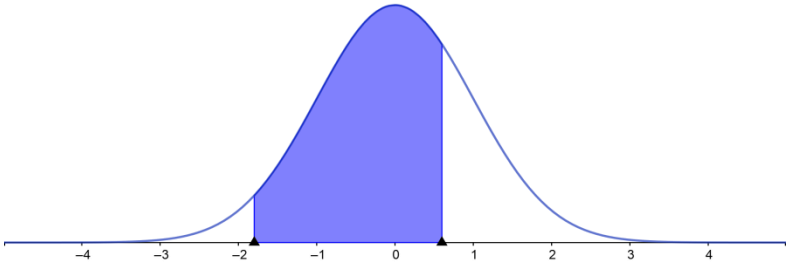

b) En este punto nos da la probabilidad y debemos calcular el valor de x, recordemos que en la distribución Normal cuando nos daba la probabilidad, debíamos usar la tabla de manera inversa.
Específicamente debemos hallar,
$P(\bar{x} > x) = 0.15$
Tipificamos
$Z = \frac{x-7}{\frac{1}{\sqrt{9}}}$ y pasamos a tener $P\left(Z > \frac{x-7}{\frac{1}{\sqrt{9}}}\right) = 0.15$, la expresión $\frac{x-7}{\frac{1}{\sqrt{9}}}$ sustituyo por k (*solo para que sea más fácil trabajar, no es necesario hacer el cambio*), y tenemos
$P(Z > k) = 0.15$, y aquí debemos ver si sumamos o restamos a 0.5 la función de distribución ($\Phi(k)$). Como nos interesa un valor de $Z > k$, y el valor de k siempre lo colocamos hacia la derecha, corresponde la siguiente operación:
$P(Z > k) = 0.15$
$0.5 - \Phi(k) = 0.15$, despejamos
$\Phi(k) = 0.5 - 0.15 = 0.35$ ($y\ este\ valor\ buscamos\ en\ el\ área, dentro\ de\ la\ tabla$)
Y tenemos que el valor de $k = 1.04$ (lleva el signo **+** porque nuestra $\Phi(k)$ resultó positiva).
Ahora pasamos a sustituir nuevamente el valor de k
$\frac{x-7}{\frac{1}{\sqrt{9}}} = k$
$\frac{x-7}{\frac{1}{\sqrt{9}}} = 1.04$, despejamos $x = 7.34$ que es el valor que queríamos hallar.

3.2 Distribución muestral de diferencia de medias

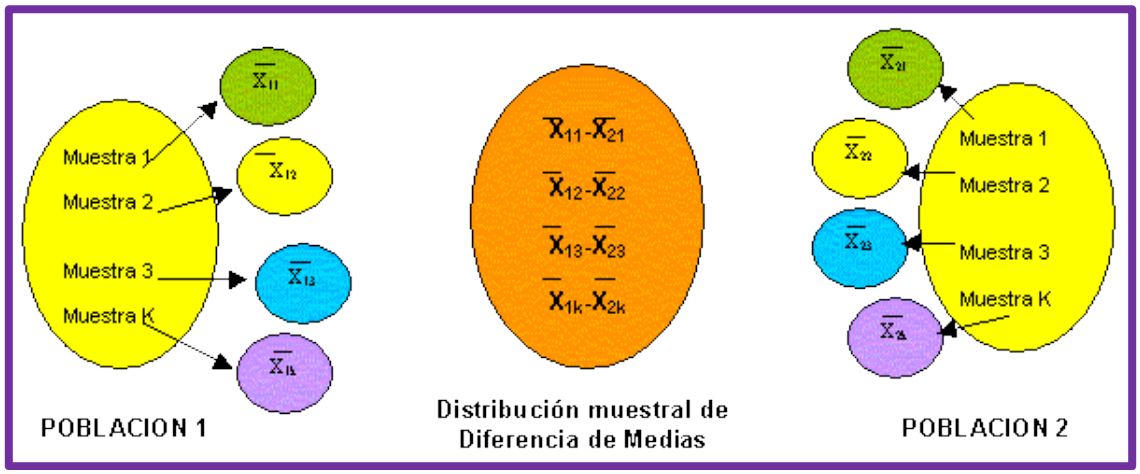

Ahora supongamos que tenemos dos poblaciones distintitas, cada una de ellas con medias μ_1 y μ_2 , y desviaciones estándar σ_1 y σ_2 respectivamente.
De la primera población extraemos una muestra de tamaño n_1 y calculamos la media muestral $\bar{x}_1$, de la segunda población tomamos una muestra de tamaño n_2 y también calculamos la media muestral $\bar{x}_2$. Ahora calculamos la diferencia entre las medias muestrales $\bar{X}_1 - \bar{X}_2$ y se repite la experiencia con todo par de muestras extraídas, donde una es de la primera población y otra de la segunda.
Al conjunto de todas esas diferencias entre medias llamaremos *Distribución muestral de la diferencia de medias*, donde el estadístico es $\bar{X}_1 - \bar{X}_2$.
Observemos que la distribución de muestreo de la diferencia de medias de una población normalmente distribuida tiene propiedades importantes a saber:

- La media de la distribución muestral de las diferencias de las medias $\bar{X}_1 - \bar{X}_2$ es igual a la diferencia entre las medias de la población, $\mu_{\bar{X}_1-\bar{X}_2} = \mu_1 - \mu_2$
- La distribución de muestreo tiene una desviación estándar (un error estándar) igual a $\sigma_{\bar{x}_1-\bar{x}_2} = \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}$

Y para calcular la probabilidad del comportamiento de la diferencia de medias en la muestra utilizaremos la siguiente fórmula para estandarizar:

$$Z = \frac{(\bar{x}_1-\bar{x}_2)-(\mu_1-\mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1}+\frac{\sigma_2^2}{n_2}}}$$

***Ejemplo 2*:** La empresa A vende mensualmente insumos de oficina por un valor medio de 1.500.000 Gs y una desviación típica de 200.000 Gs, mientras que las ventas de otra empresa B tienen un valor medio de 1.200.000 Gs con una desviación típica de 110.000 Gs. Sí se toman al azar 120 ventas mensuales de cada empresa, ¿cuál es la probabilidad de que las ventas que proceden de la empresa A tengan un valor medio que sea al menos de 250.000 Gs más que las de la empresa B?

Solución
Tenemos dos poblaciones que son las empresas A y B, que nos han arrojado los siguientes datos
$\mu_A = 1.500.000 \quad y \quad \sigma_A = 200.000$
$\mu_B = 1.200.000 \quad y \quad \sigma_B = 110.000$
De ambas poblaciones se han tomado muestras de tamaños iguales,
$n_A = n_B = 120$

Lo que queremos hallar es la
$P(\bar{x}_A \geq 250.000 + \bar{x}_B) =?$, esto es lo mismo que
$P(\bar{x}_A - \bar{x}_B \geq 250.000)$ y ya nos queda una expresión que se ajusta a nuestra fórmula de tipificación.

$$Z = \frac{(\bar{x}_1 - \bar{x}_2) - (\mu_1 - \mu_2)}{\sqrt{\frac{{\sigma_1}^2}{n_1} + \frac{{\sigma_2}^2}{n_2}}} = \frac{(250.000) - (1.500.000 - 1.200.000)}{\sqrt{\frac{200.000^2}{120} + \frac{110.000^2}{120}}} = -2.39$$

$$P(Z \geq -2.39) = 0.5 + 0.4916 = 0.9916$$

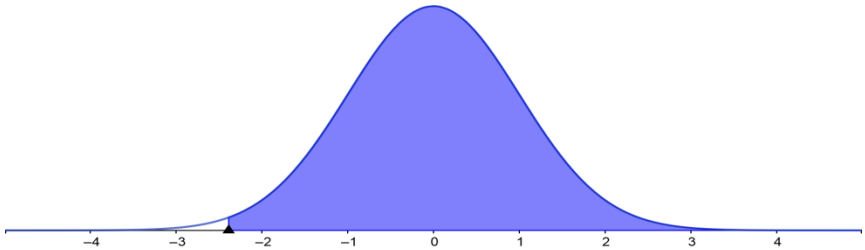

3.3 Distribución muestral de la proporción

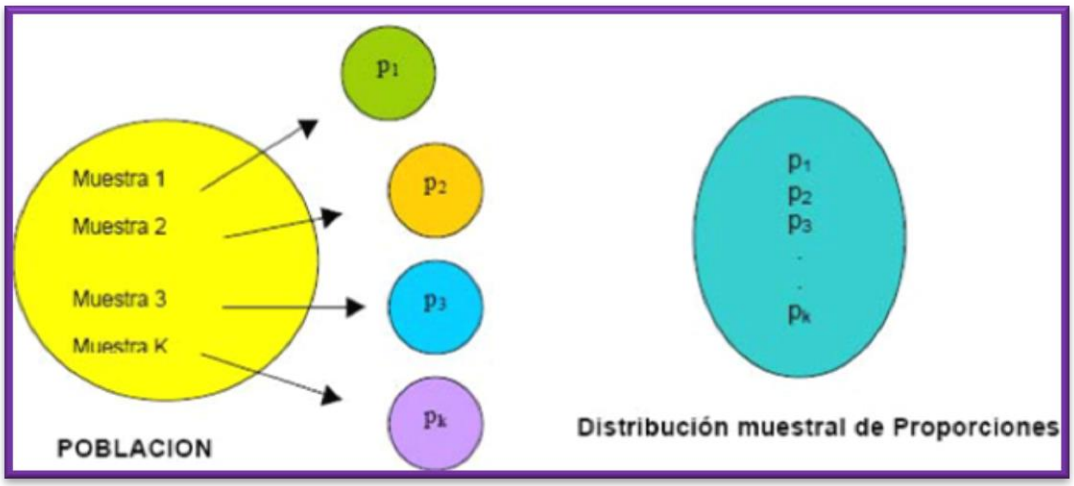

Existen ocasiones en que no estamos interesados en el promedio, sino que queremos investigar la proporción de estudiantes que ingresaron a la Universidad Nacional en su primer intento, o la proporción de estudiantes aplazados en cierta materia, etc., para este tipo de variables la distribución muestral de proporciones es la adecuada.
Esta distribución se genera de igual manera que la distribución muestral de medias, a excepción de que al extraer las muestras, de cada una de ellas se calcula el estadístico proporción (p)

$$p = \frac{x}{n} = \frac{\textit{número de observaciones de } \text{interés } (\textit{éxito})}{\textit{tamaño de la muestra}}$$

Observemos que la distribución de muestreo de una proporción de una población normalmente distribuida tiene propiedades importantes a saber:

- La media de la distribución muestral de proporciones tiene una media igual a la Proporción de la población, $\mu_P = P$
- La desviación estándar de la distribución muestral de proporciones si la población es infinita, es $\sigma_P = \sqrt{\frac{P.(1-P)}{n}}$

- Si la población es finita o el muestreo se realiza sin reemplazo, el error estándar toma la forma de $\sigma_P = \sqrt{\frac{P.(1-P)}{n}}.\sqrt{\frac{N-n}{N-1}}$, donde N es el tamaño de la población y n es el tamaño de la muestra

Y para calcular la probabilidad del comportamiento de la proporción en la muestra utilizaremos las siguientes fórmulas para estandarizar:

$z = \frac{p-P}{\sqrt{\frac{P.(1-P)}{n}}}$. , para muestreo con reemplazo y poblaciones infinitas

$z = \frac{p-P}{\sqrt{\frac{P.(1-P)}{n}}.\sqrt{\frac{N-n}{N-1}}}$, para muestreo sin reemplazo y poblaciones finitas

***Ejemplo 3*:** Se ha estimado que el 43% de los licenciados en economía consideran que es muy importante que se imparta un curso de Ética en Economía. De una población de 800 estudiantes se tomó una muestra de 80. Calcular la probabilidad de que más de la mitad de ellos opinen de ese modo

Solución

Aquí nuestra población viene a ser "Licenciados en Economía", del cual sabemos la proporción de a quienes interesan recibir un curso de Ética y el tamaño de la población, es decir, tenemos:

$P = 0.43$ y $N = 800$

De la población se ha extraído una muestra de tamaño 80, $n = 80$ y con estos datos nos pide:

$P(p > 0.5) = ?$

Debemos tipificar, utilizando la siguiente fórmula porque nuestra población es finita

$$Z = \frac{p-P}{\sqrt{\frac{P(1-P)}{n}} \times \sqrt{\frac{N-n}{N-1}}} = \frac{0.5-0.43}{\sqrt{\frac{0.43 \times 0.57}{80}} \times \sqrt{\frac{800-80}{800-1}}} = 1.33$$

$$P(Z > 1.33) = 0.5 - 0.4082 = 0.0918$$

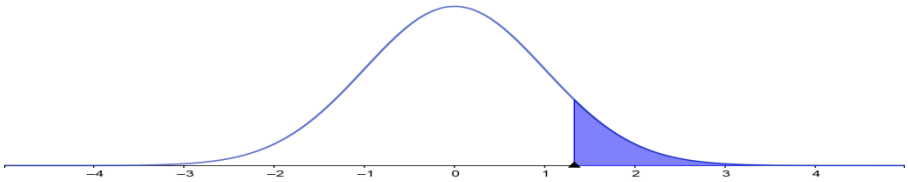

3.4 Distribuciones muestrales para diferencia de proporciones

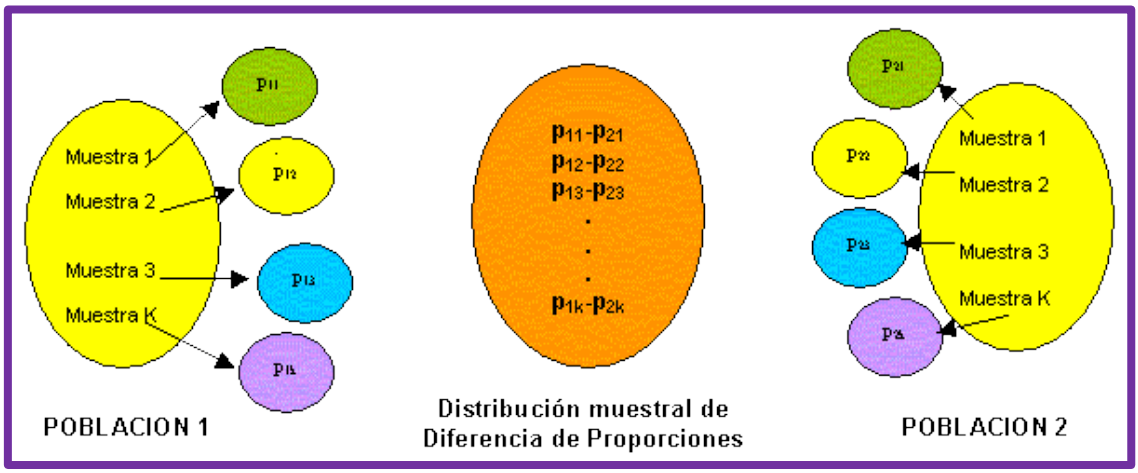

Supongamos que tenemos dos poblaciones distintas, cada una de ellas con proporciones P_1 y P_2 respectivamente
De la primera población extraemos una muestra de tamaño n_1 y calculamos la proporción muestral p_1, de la segunda población tomamos una muestra de tamaño n_2 y también calculamos la proporción muestral p_2. Luego calculamos la diferencia entre las proporciones muestrales $p_1 - p_2$ y se repite la experiencia con todo par de muestras extraídas, donde una es de la primera población y otra de la segunda.
El conjunto de todas esas diferencias entre proporciones halladas, forman la *Distribución muestral de la diferencia de proporciones*, donde el estadístico es p_1-p_2

Observemos que la distribución de muestreo de la diferencia de proporciones de una población normalmente distribuida tiene propiedades como:

- La media de la distribución muestral (valor esperado) de la diferencia entre dos proporciones es igual a la diferencia entre las proporciones de las poblaciones, $\mu_{p_1-p_2} = P_1 - P_2$
- El error estándar de la diferencia entre dos proporciones (un error estándar) igual a $\sigma_{p_1-p_2} = \sqrt{\frac{P_1.(1-P_1)}{n_1} + \frac{P_2.(1-P_2)}{n_2}}$

Y para calcular la probabilidad del comportamiento de la diferencia de proporciones en la muestra utilizaremos la siguiente fórmula para hallar Z

$$Z = \frac{(p_1 - p_2) - (P_1 - P_2)}{\sqrt{\frac{P_1(1-P_1)}{n_1} + \frac{P_2(1-P_2)}{n_2}}}$$

Ejemplo 4: Los hombres y mujeres adultos difieren en sus opiniones sobre la promulgación de una Ley. Se cree que el 12% de los hombres adultos están a favor de la Ley, mientras que sólo 10% de las mujeres adultas lo están. Si se pregunta a dos muestras aleatorias de 100 hombres y 120 mujeres su opinión sobre la promulgación de la Ley, determine la probabilidad de que el porcentaje de hombres a favor sea al menos 3% mayor que el de las mujeres.

Solución
Tenemos dos poblaciones:
Hombres adultos, que nos brinda una $P_1 = 0.12$ y las
Mujeres adultas, que nos brinda una $P_2 = 0.10$

Se han extraído muestras para analizar de ambas poblaciones, cuyos tamaños son $n_1 = 100$ y $n_2 = 120$

Nos pide calcular la siguiente probabilidad sobre las muestras tomadas $P(p_1 \geq 0.03 + p_2)$=?, esta expresión es equivalente a $P(p_1 - p_2 \geq 0.03)$

Tipificamos utilizando la siguiente fórmula

$$Z = \frac{(p_1 - p_2) - (P_1 - P_2)}{\sqrt{\frac{P_1(1-P_1)}{n_1} + \frac{P_2(1-P_2)}{n_2}}} = \frac{(0.03) - (0.12 - 0.10)}{\sqrt{\frac{0.12(1-0.12)}{100} + \frac{0.10(1-0.10)}{120}}} = 0.23$$

$$P(Z \geq 0.23) = 0.5 - 0.0910 = 0.409$$

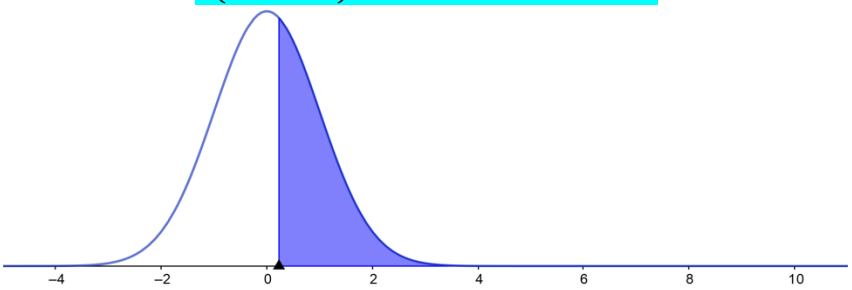

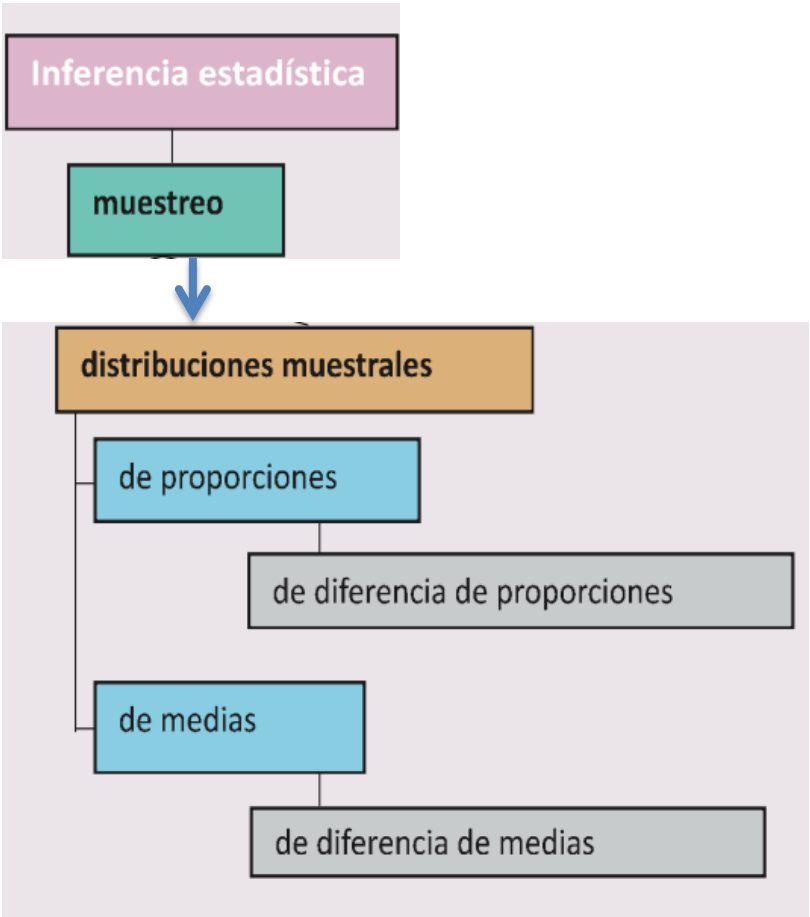

4 Bibliografía

Canavos, G. C. (1988). *Probabilidad y Estadistica. Aplicaciones y Métodos.* México: McGRAW-HILL/INTERAMERICANA DE MÉXICO, S.A DE C.V.

Kazmier, L. J. (1990). *Estadistica Aplicada a Administracion y Economia.* Mexico: Grafica Futura 2000.

Triola, M. F. (2013). *Estadística.* México: Pearson Educación.

Walpole, (2012). *Probabilidad* y *Estadistica para ingeniería y ciencias.* Mexico: PEARSON