FP-UNA - CONSTRUYENDO EL FUTURO

- Investigación de Operaciones II -

Material de lectura

Unidad 2: Teoría de Pronósticos

Facultad Politécnica UNA

Contenido

1.1. MÉTODO DELPHI 3
1.2. PANEL DE EXPERTOS: 6
1.3. MÉTODO DE INVESTIGACIÓN DE MERCADO: 7
2.1. PROMEDIO MÓVIL SIMPLE: 7
2.1.1. EJEMPLO 9
2.2. PROMEDIO MÓVIL PONDERADO: 10
2.3. PONDERACIÓN O SUAVIZADO EXPONENCIAL 12
2.3.1. EJEMPLO 14
2.4. REGRESIÓN LINEAL SIMPLE 15
2.4.1. MÉTODO DE MÍNIMOS CUADRADOS 16
2.4.2. CORRELACIÓN 17
2.4.2.1. TIPOS DE CORRELACIÓN 17
2.4.3. COVARIANZA (DEFINICIÓN) 18
2.4.3.1. COEFICIENTE DE CORRELACIÓN LINEAL 18
2.4.3.1.1. PROPIEDADES DEL COEFICIENTE DE CORRELACIÓN 19
2.4.4. COEFICIENTE DE DETERMINACIÓN 19
2.4.5. ERROR ESTÁNDAR DE LA ESTIMACIÓN 20
2.4.6. PARÁBOLA DE MÍNIMOS CUADRADOS 20
2.4.7. REGRESIÓN EXPONENCIAL 21
2.4.8. REGRESIÓN POTENCIAL 21
2.4.9. CAMBIO DE VARIABLES PARA CASOS LINEALIZABLES 21
2.4.10. EJEMPLO 22
2.4.11. EJEMPLO 26
2.5. MODELOS DE PRONÓSTICOS DE SERIES DE TIEMPO 27
2.5.1. COMPONENTES DE UNA SERIE DE TIEMPO 27
2.5.2. SUAVIZAMIENTO EXPONENCIAL CON AJUSTE DE TENDENCIA 29
2.5.2.1. EJEMPLO 30
2.5.2.2. PRECISIÓN DEL PRONÓSTICO. 32
2.5.3. PROYECCIÓN DE LA TENDENCIA 32
2.5.3.1. EJEMPLO 33
2.5.4. COMPONENTES DE TENDENCIA Y ESTACIONAL 36
2.5.4.1. MODELO MULTIPLICATIVO 37
2.5.4.2. EJEMPLO 38
2.5.5. DESESTACIONALIZACIÓN DE LAS SERIES DE TIEMPO 44
2.5.5.1.1. USO DE SERIES DE TIEMPO DESESTACIONALIZADAS PARA IDENTIFICAR TENDENCIAS 45
2.5.6. AJUSTES ESTACIONALES 48

1. Métodos cualitativos

1.1. MÉTODO DELPHI

Una de las técnicas de elaboración de pronósticos de uso más común es el **método Delphi**. Esta técnica intenta elaborar pronósticos por medio de Un "consenso de grupo". En su aplicación usual, se pide a los miembros de un panel de expertos, quienes están separados físicamente y no se conocen entre sí, que respondan una serie de cuestionarios. Las respuestas del primer cuestionario se tabulan y utilizan para preparar un segundo cuestionario que contiene la información y las opiniones de todo el grupo. Luego se pide a cada uno de los que responden que reconsideren y revisen su respuesta previa en vista de la información proporcionada por el grupo. Este proceso continúa hasta que el coordinador considera que se ha llegado a cierto grado de consenso. La meta del método Delphi no es producir una sola respuesta como salida, sino obtener una variedad relativamente estrecha de opiniones con las cuales coincida la mayoría de los expertos.

1.1.1. Ejemplo – Ampliación del centro de ITV

SITUACIÓN: Debido a que hay una gran congestión en los meses diciembre, enero y febrero que se viene observando en los últimos 4 años, el consejo de administración de la empresa va a realizar una ampliación de la estación de ITV. La estación cuenta actualmente con 10 puestos de revisión y 15 trabajadores. En los meses de verano la utilización de los puestos es del 99.99% con picos puntuales en viernes y en fines de semana. Sin embargo, el resto del año la ocupación media de la estación es de un 60%.

PREGUNTAS:

1. ¿Sería conveniente la ampliación de las instalaciones para el próximo año?
2. ¿En qué período del año sería más conveniente el inicio de las obras?
3. ¿Cuántos puestos de revisión convendría añadir?
4. ¿Sería necesaria la ampliación de la plantilla? ¿En cuántos trabajadores?

ALGUNAS DE LAS RESPUESTAS DE NUESTROS EXPERTOS:

Experto 1:

1. Si, sería conveniente si se quieren mantener los clientes, pues si las colas aumentan mucho y el tiempo medio de espera para la revisión se ve incrementado, los conductores podría migrar hacia otras estaciones.
2. En los meses de invierno, pues se debe intentar que las obras afecten lo menos posible al funcionamiento normal de la estación.
3. Dos sería un buen número, ya que no interesa realizar una ampliación muy alta si sólo vamos a necesitar todos los puntos de revisión durante 3 meses al año. Por otro lado, con dos puntos de revisión adicionales el tiempo de espera medio para la revisión se puede ver reducido de forma considerable.
4. En principio, se podría mantener la plantilla actual y en los meses me más trabajo contratar a más trabajadores. Pues el número actual de trabajadores de la central ya es bastante elevado.

Experto 2:

1. ¡Si, claro! Así podríamos ofrecer una calidad mucho mejor al cliente, sin retrasos, esperas, ni exageradas aglomeraciones.
2. En marzo/abril, ya que son los meses posteriores a la avalancha y son lo suficientemente tranquilos para que el funcionamiento normal del centro no se vea perjudicado.
3. Con 3 o 4 puestos más se podría dar un servicio mucho mejor.
4. La verdad es que en los meses de verano si que se debería contratar a más trabajadores ya que apenas se da abasto en esos días, pero para el resto del año no haría falta.

Experto 3:

1. Para mi es conveniente, ya que agilizaría el proceso de revisión de los vehículos reduciendo la espera y esto para los clientes es siempre importante.

Por lo tanto esta ampliación atraerá nuevos clientes por la rapidez del servicio.

2. El inicio de las obras deberían de ser justo al finalizar los meses de verano, para que estén operando los nuevos puestos para el próximo verano.

3. Una ampliación de 3 nuevos puestos de revisión serian suficiente.

4. Sería conveniente la ampliación de la plantilla. Contratar unos 5 trabajadores más.

RESULTADOS DEL MÉTODO

Con respecto a las cuestiones enunciadas las respuestas se pueden resumir en lo siguiente:

1. Según los expertos sería necesaria la ampliación de la central, ya que supondría una inversión de cara a aumentar la satisfacción de los clientes y por lo tanto aumentar su fidelidad y las perspectivas de negocio, atrayendo también a nuevos clientes.

2. Según nuestros expertos, se ha llegado a la conclusión de que las obras deberían comenzar inmediatamente después de los meses de verano, cuando se produce la avalancha, de este modo el impacto de las obras sería mínimo y la ampliación estaría concluida antes de la campaña siguiente.

3. Según las respuestas, se ha llegado a la conclusión de que se haría una ampliación de 3 puestos, lo que supondría un aumento de la eficiencia y rapidez en la atención al cliente.

4. El aumento de la plantilla será necesario, sobre todo en los meses de verano. Falta ver si las contrataciones serían de carácter temporal o fijo.

Con los resultados obtenidos al aplicar el método Delphi la empresa ha decidido tomar las siguientes medidas:

• Se decide ampliar la central con tres puestos de revisión más.

• El inicio de las obras se realizará a finales de abril, con lo que se espera que estén concluidas a principios de octubre.

• Se ha decidido contratar a 2 operadores más con contratación fija y 2 más con contrato temporal en los meses de verano.

CONCLUSIONES:

Hemos realizado el método de la experiencia Delphi y hemos observado algunas ventajas significativas como el mantener el anonimato de los expertos haciendo que la influencia entre los componentes del grupo sea mínima y la facilidad de la comunicación entre expertos, ya que al utilizar las herramientas de Internet, no es necesario que el grupo se reúna físicamente, facilitando que los expertos den su opinión más rápidamente desde cualquier lugar y en el momento que quieran. Por otro lado, con este método se consiguen mejores soluciones al problema, ya que el sistema de realimentación hace que los expertos conozcan las ideas del resto de expertos y puedan usarlas para reflexionar y elaborar sus propias conclusiones.

1.2. PANEL DE EXPERTOS:

El panel de expertos puede definirse como un grupo de especialistas independientes y reputados en al menos uno de los campos concernidos por el programa que se va a evaluar, al que se reúne para que emita un juicio colectivo y consensuado sobre dicho programa. Según se les solicite, el juicio emitido puede hacer referencia a la puesta en práctica o a los efectos del conjunto o de una parte del programa.

El objetivo de esta herramienta es utilizar el conocimiento que los expertos poseen de una materia para evaluar políticas, programas o proyectos llevados a cabo en este contexto en concreto.

Algunas de sus características son:

- Es una técnica similar al Método Delphi se diferencia de esta en que no existen secretos sobre la identidad del emisor de las opiniones y no existe retroalimentación dirigida desde el exterior.
- Se estimula la comunicación.
- Se basa en la suposición de que varios expertos serán capaces de producir un pronóstico mejor que una sola persona.
- Algunas veces los factores sociales influyen en los pronósticos y por este motivo no reflejan un consenso verdadero.

- Existe la posibilidad de que emerja un grupo dominante que anule la interacción adecuada y se logre un consenso por la capacidad de la argumentación y no por la validez de la misma.

1.3. MÉTODO DE INVESTIGACIÓN DE MERCADO:

1. ***Consulta a vendedores*:** En este enfoque, cada persona de ventas estima las ventas en su región; estos pronósticos se revisan para asegurar que sean realistas y después se combinan a niveles de región y nacional, para llegar a un pronóstico general.

2. ***Encuesta al mercado de consumidores*:** Este método solicita información a los consumidores o clientes potenciales respecto a sus planes de compra futuros. Puede ayudar no solo a elaborar un pronóstico, sino también a mejorar el diseño del producto y la planeación de nuevos productos.

2. MÉTODOS CUANTITATIVOS

2.1. PROMEDIO MÓVIL SIMPLE:

Definamos:

$y_{t-1} =$ valores observados en el periodo $t-1$

$y_t =$ pronóstico de valores en el periodo t

$n =$ número de periodos por promediar

El modelo más simple en la categoría de promedios móviles es el **promedio móvil simple de *n* periodos.** En este modelo se utiliza el promedio de un número fijo (digamos, *n*) de las observaciones más recientes para estimar el valor siguiente de *y*. Por ejemplo, si *n* es igual a 4, entonces, después de haber observado el valor de *y* en el periodo 15, nuestra estimación para el periodo 16 sería:

$$\hat{y}_{16} = \frac{y_{15} + y_{14} + y_{13} + y_{12}}{4}$$

En general:

$$\hat{y}_{t+1} = \frac{1}{n}(y_t + y_{t-1} + \ldots + y_{t-n+1})$$

Un promedio móvil simple resultará siempre menor que los datos en aumento y mayor que los datos en disminución. Por lo tanto, si aparecen amplias elevaciones o caídas, los promedios móviles simples no se desempeñarán bien. Se ajustan mejor a datos con pequeños ascensos y descensos erráticos, dando alguna estabilidad frente a perturbaciones aleatorias.

El promedio móvil simple tiene dos inconvenientes, uno filosófico y otro operacional. El inconveniente *filosófico* se centra en el hecho de que al calcular un pronóstico (digamos, $\hat{y}_8$), a la observación más reciente (y_7) no se le da una mayor importancia o coeficiente que a una observación más antigua, como y_5. Esto se debe a que a cada una de las últimas n observaciones se le asigna el coeficiente $\frac{1}{n}$. Este procedimiento de asignar coeficientes iguales es opuesto a la intuición personal de que en muchos casos los datos más recientes deben contener más información sobre el futuro que los datos más antiguos.

El segundo inconveniente, que es *operacional*, es que en el promedio móvil, si se van a incluir n observaciones, deben extraerse entonces $(n - 1)$ elementos de datos para combinarse con la observación actual (la número n). Todos estos datos deben ser almacenados de alguna manera a fin de calcular el pronóstico. Éste no es un problema serio si sólo se trata de una pequeña cantidad de pronósticos. La situación cambia bastante para aquella empresa que necesite pronosticar la demanda de miles de productos individuales en una base de artículo por artículo.

Para saber qué tan bien funciona un modelo o para comparar un modelo con otros, los valores pronosticados se comparan con los valores reales u observados. El error del pronóstico (o desviación) se define como:

Error de pronóstico = valor real - valor pronosticado

Una medida de exactitud es la **desviación media absoluta (DMA)**, que se calcula tomando la suma de los valores absolutos de los errores de pronósticos individuales y, luego, dividiendo entre el número de errores (n):

$$\text{DMA} = \frac{\sum |\text{error del pronóstico}|}{n}$$

Además de la DMA, en muchas ocasiones se emplean otras medidas de la exactitud de los errores históricos al pronosticar. Una de las más comunes es el **error cuadrado medio (ECM)**, que es el promedio de los cuadrados de los errores:

$$\text{ECM} = \frac{\sum (\text{error})^2}{n}$$

Además de la DMA y el ECM, algunas veces se utiliza el **error medio absoluto porcentual (EMAP)**, que es el promedio de los valores absolutos de los errores expresados como porcentajes de los valores reales. Esto se calcula como:

$$\text{EMAP} = \frac{\sum \left| \frac{\text{error}}{\text{real}} \right|}{n} 100\%$$

2.1.1. Ejemplo

El señor Víctor Kowalski decide utilizar los datos de ventas mensuales del año anterior de puntales de acero inoxidable y ver qué tan bien hubieran funcionado si el año anterior la empresa hubiera utilizado modelos de pronósticos simples.

Está interesado en elaborar un pronóstico de las ventas con un mes de anticipación; esto es, tomará los valores históricos conocidos $y_1, \ldots, y_{t-1}$ (demanda en los meses 1 a $t-1$) y utilizará esta información para producir $\hat{y}_t$, el pronóstico de la demanda en el mes t. En otras palabras, tomará las ventas pasadas reales, hasta mayo por ejemplo, y las utilizará para pronosticar las ventas de junio; después utilizará las ventas hasta junio para pronosticar las ventas en julio, y así sucesivamente. El proceso producirá una secuencia de valores $\hat{y}_t$. Al comparar estos valores con los valores y_t reales

observados, se obtiene un indicativo de cómo hubiera funcionado el modelo de pronóstico si realmente hubiera estado en uso el año anterior.

La aplicación de promedios móviles de tres y cuatro periodos a los datos de ventas de puntales de acero aparecen en la tabla siguiente:

	A	B	C	D	E	F
1	Mes	Ventas reales (000)	Pronóstico Prom.Móvil 3 Meses	Error absoluto	Pronóstico Prom.Móvil 4 Meses	Error absoluto
2	Enero	20				
3	Febrero	24				
4	Marzo	27				
5	Abril	31	23.67	7.33		
6	Mayo	37	27.33	9.67	25.50	11.50
7	Junio	47	31.67	15.33	29.75	17.25
8	Julio	53	38.33	14.67	35.50	17.50
9	Agosto	62	45.67	16.33	42.00	20.00
10	Septiembre	54	54.00	0.00	49.75	4.25
11	Octubre	36	56.33	20.33	54.00	18.00
12	Noviembre	32	50.67	18.67	51.25	19.25
13	Diciembre	29	40.67	11.67	46.00	17.00
14						
15			Suma =	114.00	Suma =	124.75
16			DMA =	12.67	DMA =	15.59

Tabla 1: Promedios móviles simples de tres y cuatro periodos de las ventas de puntales de acero

Dado que el promedio móvil de tres meses da una DMA de 12.67, en tanto que el promedio móvil de cuatro meses da una DMA de 15.59, parece (al menos históricamente) que la inclusión de un mayor número de datos históricos perjudica en vez de beneficiar la precisión del pronóstico.

2.2. PROMEDIO MÓVIL PONDERADO:

La idea de que los datos recientes son más importantes que los datos más antiguos puede ponerse en práctica con un **promedio móvil ponderado de n periodos**. Éste generaliza el concepto de un promedio móvil simple de n periodos donde, como hemos visto, cada coeficiente de ponderación es $\frac{1}{n}$. En esta forma más general, tomando $n = 3$ como ejemplo específico, podríamos hacer que:

$$\hat{y}_7 = \alpha_0 y_6 + \alpha_1 y_5 + \alpha_2 y_4$$

donde las α (que se conocen como coeficientes de ponderación) son números no negativos, escogidos de forma que los coeficientes más pequeños sean asignados a los datos más antiguos y que todos los coeficientes sumen 1. Existen, por supuesto, innumerables maneras de

seleccionar un conjunto de α que satisfaga estos criterios. Por ejemplo, si el promedio ponderado debe incluir las últimas tres observaciones (un promedio móvil ponderado de tres periodos), uno podría determinar que:

$$\hat{y}_7 = \frac{3}{6}y_6 + \frac{2}{6}y_5 + \frac{1}{6}y_4$$

De manera alternativa, se podría definir:

$$\hat{y}_7 = \frac{5}{10}y_6 + \frac{3}{10}y_5 + \frac{2}{10}y_4$$

En ambas expresiones tenemos coeficientes de ponderación decrecientes cuya suma es 1.

Para tener una idea de cómo funciona, Víctor aplica el promedio móvil ponderado de tres meses con coeficientes iniciales de $\frac{3}{6}$, $\frac{2}{6}$, $\frac{1}{6}$ a los datos históricos del puntal de acero inoxidable.

Comparando la nueva DMA obtenida por Víctor de 11.04, con la DMA del promedio móvil simple de tres meses (12.67) y el promedio móvil simple de cuatro meses (15.59), se confirma la sospecha de que los resultados de ventas recientes son un mejor indicador de las ventas futuras que los datos más antiguos.

	A	B	C	D	E	F	G
1	*alfa2 =*	0.167		**Mes**	**Ventas reales (000)**	**Pronóstico Prom.Móvil 3 Meses**	**Error absoluto**
2	*alfa1 =*	0.333		Enero	20		
3	*alfa0 =*	0.500		Febrero	24		
4	*SUMA DE COEF.POND. =*	1.00		Marzo	27		
5				Abril	31	24.83	6.17
6				Mayo	37	28.50	8.50
7				Junio	47	33.33	13.67
8				Julio	53	41.00	12.00
9				Agosto	62	48.33	13.67
10				Septiembre	54	56.50	2.50
11				Octubre	36	56.50	20.50
12				Noviembre	32	46.33	14.33
13				Diciembre	29	37.00	8.00
14							
15						**Suma =**	99.33
16						**DMA =**	11.04

Tabla 2: Promedios móviles ponderados de tres periodos de las ventas de puntales de acero

OBSERVACIÓN: A pesar de que los promedios móviles ponderados le dan mayor peso a los datos más recientes, esto no resuelve los problemas operacionales de almacenamiento de datos, ya que (n – 1) elementos históricos de datos aún deben almacenarse.

2.3. PONDERACIÓN O SUAVIZADO EXPONENCIAL

Vimos que, utilizando un promedio móvil ponderado, hay muchas maneras diferentes de asignar coeficientes decrecientes de ponderación que sumen 1. Una de ellas se llama **ponderación o suavizado exponencial,** que es un nombre abreviado para *promedio móvil ponderado exponencialmente*.

Éste es un esquema que pondera los datos recientes con mayor peso que los datos pasados, con coeficientes que sumen 1, pero evita el problema operacional. En este modelo, para cualquier $t \geq 1$, el pronóstico para el periodo $t+1$, identificado como $\hat{y}_{t+1}$, es una suma ponderada (con coeficientes que suman 1) de las *ventas observadas en el periodo* t (es decir, y_t) y del *pronóstico para el periodo* t (que era $\hat{y}_t$). En otras palabras:

$$\underbrace{\hat{y}_{t+1}}_{\text{Pronóstico para } t+1} = \alpha \underbrace{y_t}_{\text{Observado en } t} + (1-\alpha)\underbrace{\hat{y}_t}_{\text{Pronóstico para } t}$$

donde α es una constante especificada por el usuario tal que $0 \leq \alpha \leq 1$. El valor asignado a α determina cuánto peso relativo se le da al coeficiente de ponderación de la observación más reciente al calcular el pronóstico del periodo siguiente. Observemos en la ecuación anterior que si a α se le asigna un valor cercano a 1, casi todo el peso se coloca en la demanda real del periodo t. La ponderación exponencial tiene importantes ventajas de cálculo. Para calcular $\hat{y}_{t+1}$, sólo debe almacenarse $\hat{y}_t$, (junto con el valor de α). Lo que es agradable en la ponderación exponencial es que al guardar α y el último pronóstico, *de manera implícita* se están almacenando todos los pronósticos anteriores.

A fin de comprender mejor el modelo de ponderación exponencial, observemos que cuando $t = 1$ la expresión utilizada para definir $\hat{y}_2$ es:

$$\hat{y}_2 = \alpha y_1 + (1-\alpha)\hat{y}_1$$

En esta expresión $\hat{y}_1$ es una "estimación inicial" del valor para y en el periodo 1, e y_1 es el valor observado del periodo 1. Para comenzar el pronóstico de ponderación exponencial, necesitamos establecer esta "estimación inicial", por ejemplo podemos considerar $\hat{y}_1 = y_1$.

Debido a la importancia del modelo de ponderación exponencial básico, merece la pena explorar con más detalle cómo funciona y cuándo puede aplicarse con éxito en modelos reales.

Examinaremos ahora algunas de sus propiedades. Para comenzar, observemos que si $t \geq 2$, es posible sustituir $t - 1$ en lugar de t, para obtener:

$$\hat{y}_t = \alpha y_{t-1} + (1 - \alpha)\hat{y}_{t-1}$$

Al sustituir esta relación para $\hat{y}_t$, de nuevo en la expresión original de $\hat{y}_{t+1}$ se obtiene para $t \geq 2$:

$$\hat{y}_{t+1} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + (1 - \alpha)^2 \hat{y}_{t-1}$$

Llevando a cabo exitosamente sustituciones similares, llegamos a la siguiente expresión general para $\hat{y}_{t+1}$:

$$\begin{aligned}\hat{y}_{t+1} = \alpha y_t + \alpha(1 - \alpha)y_{t-1} + \alpha(1 - \alpha)^2 y_{t-2} + \ldots \\ + \alpha(1 - \alpha)^{t-1} y_1 + (1 - \alpha)^t \hat{y}_1\end{aligned}$$

Por ejemplo:

$$\hat{y}_4 = \alpha y_3 + \alpha(1 - \alpha)y_2 + \alpha(1 - \alpha)^2 y_1 + (1 - \alpha)^3 \hat{y}_1$$

Dado que usualmente $0<\alpha<1$, es obvio que $0<1-\alpha<1$. Por lo tanto:

$$\alpha > \alpha(1 - \alpha) > \alpha\,(1 - \alpha)^2$$

En otras palabras, en el ejemplo anterior y_3, la observación más reciente, recibe un peso mayor que y_2, que a su vez recibe un peso mayor que y_1. Esto ilustra la propiedad general de un modelo de ponderación exponencial: *que los coeficientes de las* "y" *van decreciendo conforme los datos son más antiguos*. También se puede demostrar que *la suma de todos los coeficientes (incluyendo el coeficiente de* $\hat{y}_1$*) es 1*; esto es en el caso de $\hat{y}_4$, por ejemplo:

$$\alpha + \alpha(1 - \alpha) + \alpha(1 - \alpha)^2 + (1 - \alpha)^3 = 1$$

Así, hemos visto que el valor general de $\hat{y}_{t+1}$ es una suma ponderada de *todas las observaciones anteriores* (incluyendo el último valor observado, y_t). Aún más, los coeficientes suman 1 y son decrecientes entre más antiguas sean las observaciones históricas. El último término de la suma $\hat{y}_1$, no es una

observación histórica. Recuerde que ésta fue una "estimación" de y_1. Ahora podemos observar que conforme *t* aumenta, decrece la influencia de $\hat{y}_1$ sobre $\hat{y}_{t+1}$ y con el tiempo se vuelve despreciable. Para ver esto, observemos que el coeficiente de $\hat{y}_t$ es $(1-\alpha)^t$. Por lo tanto, el peso asignado a $\hat{y}_1$ decrece exponencialmente con *t*. Incluso si α es pequeño (lo que haría $[1-\alpha]$ cercano a 1), el valor de $(1-\alpha)^t$ decrece rápidamente.

Por ejemplo, si $\alpha = 0.1$ y $t = 20$, entonces $(1-\alpha)^t = 0.12$. Si $\alpha = 0.1$ y $t = 40$, entonces $(1-\alpha)^t = 0.015$. Por lo tanto, tan pronto como se hayan obtenido suficientes datos, el valor de $\hat{y}_{t+1}$ resultará bastante insensible a la elección de $\hat{y}_1$. Obviamente, el valor de α, que es un parámetro escogido por el administrador, afecta el desempeño del modelo. Como podemos ver explícitamente, es el peso de ponderación dado al valor de dato (y_t) observado más recientemente. Esto implica que entre mayor sea el valor de α, más fuertemente reaccionará el modelo a la última observación (llamamos a esto un pronóstico *sensible*). Esto, como veremos, puede ser o no deseable.

2.3.1. Ejemplo

Continuando con el problema de Víctor Kowalski, podremos ver en la siguiente tabla la aplicación de la ponderación exponencial a los datos de los puntales de acero inoxidable. En dicha tabla se muestran las ventas reales y las ventas estimadas para 12 meses con un valor inicial de $\alpha = 0{,}5$.

	A	B	C	D	E	F	G
1	*alfa =*	0.500		**Mes**	**Ventas reales (000)**	**Ventas pronosticadas**	**Error absoluto**
2				Enero	20	20.00	
3				Febrero	24	20.00	4.00
4				Marzo	27	22.00	5.00
5				Abril	31	24.50	6.50
6				Mayo	37	27.75	9.25
7				Junio	47	32.38	14.63
8				Julio	53	39.69	13.31
9				Agosto	62	46.34	15.66
10				Septiembre	54	54.17	0.17
11				Octubre	36	54.09	18.09
12				Noviembre	32	45.04	13.04
13				Diciembre	29	38.52	9.52
14							
15						**Suma =**	109.17
16						**DMA =**	9.92

Tabla 3: Suavizado exponencial de las ventas de puntales de acero con $\alpha = 0.5$

También se ha calculado la DMA de febrero a diciembre. De hecho, el modelo de ponderación exponencial con $\alpha = 0.5$ da una DMA inferior (9.92) al de los modelos de promedios móviles simples (12.67) o a nuestra estimación inicial del modelo de promedios móviles ponderados (11.04).

La DMA es menor que el que había obtenido con varios de los modelos anteriores, y los cálculos son simples. Desde el punto de vista de los cálculos es razonable considerar la ponderación exponencial como una manera viable de pronosticar las ventas de muchos de los productos que la empresa tiene en inventario.

2.4. REGRESIÓN LINEAL SIMPLE

La ecuación de una línea recta es $y = a + bx$, a partir de ella definimos el modelo de regresión lineal simple como:

$$Y = \beta_0 + \beta_1 X$$

Donde β_0 y β_1 son parámetros poblacionales.

- β_0: representa la ordenada al origen, es decir el punto donde la línea recta corta al eje Y.
- β_1: representa la pendiente de la recta, el cambio promedio esperado en Y por cada incremento unitario de X.

Pero para cualquier investigación, en realidad, se toman muestras y sobre el resultado de la muestra se infiere a toda la población; eso hace que el modelo contenga un término aleatorio o término de error y por lo tanto nuestro modelo queda de la siguiente forma:

$$Y_i = \beta_0 + \beta_1 X + \varepsilon_i$$

Donde β_0 y β_1 son parámetros poblacionales y ε_i es el error estocástico, por trabajar con muestras.

Debemos saber que la Regresión Lineal Simple exige ciertos requisitos para ser implementada. Algunos de ellos son:

- Tanto la variable dependiente como independiente deben ser cuantitativas continuas

- El término de error debe tener distribución normal, el promedio de estos errores debe ser cero y la varianza de ellos debe ser constante.
- Debe existir relación lineal entre las dos variables analizadas.

A partir de una muestra estimamos una ecuación de regresión lineal, la misma queda expresada como:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

- $\hat{\beta}_0$: es la estimación puntual de β_0. Para efectos prácticos, el valor indicado en $\hat{\beta}_0$ es el valor que asume la variable **Y** cuando la **X** vale cero.
- $\hat{\beta}_1$: es el estimador puntual de β_1. El valor numérico de $\hat{\beta}_1$ nos dice en cuanto varía **Y** por cada incremento unitario de **X**.

2.4.1. Método de mínimos cuadrados

Para encontrar los estimadores de los parámetros, utilizaremos el método de mínimos cuadrados. El método de mínimos cuadrados consiste en minimizar la función de mínimos cuadrados. Es por eso que primero debemos definir la función mencionada:

La función de mínimos cuadrados está dada por:

$$L = \sum_{i=1}^{n} \varepsilon_i^2$$

Si de $Y_i = \beta_0 + \beta_1 X + \varepsilon_i$ despejamos ε_i y sustituimos dicha expresión en la ecuación anterior, tendremos:

$$L = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} (Y_i - \beta_0 - \beta_1 X_i)^2$$

Luego, buscaremos los valores de β_0 y β_1 que minimicen la función de mínimos cuadrados. Esto requiere que derivemos la función con respecto a los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$ y que hagamos todos los procedimientos para la minimización. Así obtenemos las siguientes ecuaciones que nos permitirán estimar los parámetros a partir de los datos muestrales.

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} X_i Y_i - \frac{\sum_{i=1}^{n} X_i \sum_{i=1}^{n} Y_i}{n}}{\sum_{i=1}^{n} X_i^2 - \frac{\left(\sum_{i=1}^{n} X_i\right)^2}{n}}$$

$$\hat{\beta}_0 = \overline{Y} - \hat{\beta}_1 \overline{X}$$

Además recordamos que $\overline{Y} = \frac{\sum_{1}^{n} Y_i}{n}$, y $\overline{X} = \frac{\sum_{1}^{n} X_i}{n}$

2.4.2. Correlación

La **correlación** trata de establecer la relación o dependencia que existe entre las dos variables que intervienen en una **distribución bidimensional**.

Es decir, determinar si los cambios en una de las variables influyen en los cambios de la otra. En caso de que suceda, diremos que las variables están correlacionadas o que hay **correlación** entre ellas.

2.4.2.1. Tipos de correlación

- **Correlación directa:** La correlación directa se da cuando al aumentar una de las variables la otra aumenta. La recta correspondiente a la nube de puntos de la distribución es una recta creciente.

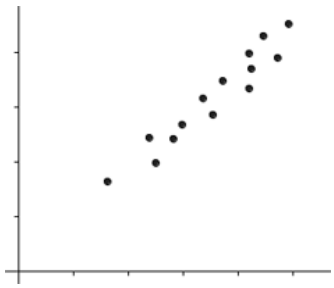

Figura 1: Correlación Directa
Fuente:http://www.vitutor.com/estadistica/bi/coeficiente_correlacion.html

- **Correlación inversa:** La correlación inversa se da cuando al aumentar una de las variables la otra disminuye. La recta correspondiente a la nube de puntos de la distribución es una recta decreciente.

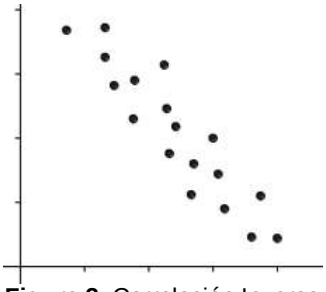

Figura 2: Correlación Inversa
Fuente:http://www.vitutor.com/estadistica/bi/coeficiente_correlacion.html

- **Correlación nula:** La correlación nula se da cuando no hay dependencia de ningún tipo entre las variables. En este caso se dice que las variables son incorreladas y la nube de puntos tiene una forma redondeada.

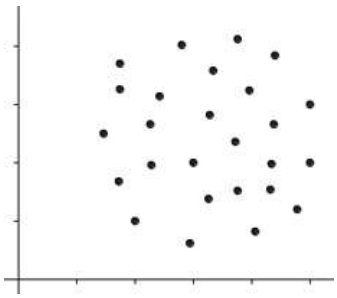

Figura 3: Correlación Nula
Fuente:http://www.vitutor.com/estadistica/bi/coeficiente_correlacion.html

2.4.3. COVARIANZA (Definición)

Una medida del grado en que dos variables aleatorias se mueven en la misma dirección o en direcciones opuestas la una respecto a la otra. En otras palabras, si dos variables aleatorias generalmente se mueven en la misma dirección se dirá que tienen una covarianza positiva. Si tienden a moverse en direcciones opuestas, se dirá que tienen una covarianza negativa.

2.4.3.1. Coeficiente de correlación lineal

El coeficiente de correlación lineal es el cociente entre la covarianza y el producto de las desviaciones típicas de ambas variables.

$$r = \frac{\sigma_{xy}}{\sigma_x . \sigma_y}$$

El coeficiente de correlación lineal se expresa mediante la letra r.

$$r = \frac{n.\sum xy - \left(\sum x\right).\left(\sum y\right)}{\sqrt{\left[n.\sum x^2 - \left(\sum x\right)^2\right]\left[n.\sum y^2 - \left(\sum y\right)^2\right]}}$$

2.4.3.1.1. Propiedades del coeficiente de correlación

- Si la covarianza es positiva, la correlación es directa.
- Si la covarianza es negativa, la correlación es inversa.
- Si la covarianza es nula, no existe correlación.
- El coeficiente de correlación lineal es un número real comprendido entre −1 y 1; o sea −1 ≤ r ≤ 1
- Si el coeficiente de correlación lineal toma valores cercanos a −1 la correlación es fuerte e inversa, y será tanto más fuerte cuanto más se aproxime r a −1.
- Si el coeficiente de correlación lineal toma valores cercanos a 1 la correlación es fuerte y directa, y será tanto más fuerte cuanto más se aproxime r a 1.
- Si el coeficiente de correlación lineal toma valores cercanos a 0, la correlación es débil.
- Si r = 1 ó −1, los puntos de la nube están sobre la recta creciente o decreciente.

2.4.4. Coeficiente de determinación

Luego de que ajustamos una recta de regresión a la nube de observaciones del gráfico de dispersión de los datos, es importante disponer de una medida que mida la bondad del ajuste realizado, un criterio que nos permita decidir si la función que utilizamos es suficiente o si debemos buscar modelos alternativos.

Como medida de bondad de ajuste, utilizamos el coeficiente de determinación r^2 definido como sigue:

$$r^2 = \frac{\sigma^2{}_{xy}}{\sigma^2{}_x.\sigma^2{}_y}$$

Como trabajamos con muestras, el coeficiente de determinación se calcula elevando al cuadrado el coeficiente de correlación lineal.

$$r^2 = \frac{\left[n.\sum xy - \left(\sum x\right).\left(\sum y\right)\right]^2}{\left[n.\sum x^2 - \left(\sum x\right)^2\right].\left[n.\sum y^2 - \left(\sum y\right)^2\right]}$$

El valor de r^2 indica el porcentaje de la variación de la variable dependiente Y que se explica por la recta de regresión estimada.

El valor de r^2 varía entre 0 y 1, cuando más cercano a 1 sea, mejor es el ajuste lineal.

- Si $r^2 = 0{,}81$, por ejemplo, significa que el 81% de la variabilidad de Y es explicada por la recta de regresión estimada. El 19% faltante, lo atribuimos a factores ajenos al modelo establecido.
- Si $r^2 = 0{,}35$, significa que, apenas, el 35% de la variabilidad de Y es explicada por la recta de regresión estimada. El 65% faltante, lo atribuimos a factores ajenos al modelo establecido, por lo que sería recomendable recurrir a otros modelos.

2.4.5. Error estándar de la estimación

Si $\hat{y}$ es la estimación de y para un valor determinado de x, entonces la medida de la dispersión alrededor de la recta de regresión está dada por $s_{y.x}$, que es el **Error estándar de la estimación.**

$$s_{y.x} = \sqrt{\frac{\sum\left(y - \hat{y}\right)^2}{n-2}}$$

Recordemos que $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ y que $s_{y.x}$ tiene el menor valor posible, porque la estimación por mínimos cuadrados fundamenta que los coeficientes son calculados con el menor error posible.

2.4.6. Parábola de mínimos cuadrados

Debemos entender que no siempre una recta es la mejor opción para el ajuste de una función a una serie de datos, además de la recta podemos utilizar una parábola o incluso otra relación polinómica.

Un ajuste por medio de una parábola tendría por lo tanto la siguiente forma:

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \hat{\beta}_2 x^2$$

Donde $\hat{\beta}_0$, $\hat{\beta}_1$ y $\hat{\beta}_2$ son los estimaciones de los parámetros β_0, β_1 y β_2 y se calculan por el método de métodos de mínimos cuadrados.

2.4.7. Regresión exponencial

Es aquella en la que la función de ajuste es una función exponencial del tipo:

$$\hat{y} = \hat{\alpha}.\hat{\beta}^x$$

La regresión exponencial, aunque no es lineal es linealizable tomando logaritmos y haciendo el cambio pertinente de variables.

2.4.8. Regresión potencial

Es aquella en la que la función de ajuste es una función exponencial del tipo:

$$\hat{y} = \hat{\alpha}.x^{\hat{\beta}}$$

La regresión potencial, aunque no es lineal es linealizable tomando logaritmos y haciendo el cambio pertinente de variables.

2.4.9. Cambio de variables para casos linealizables

Función	Cambio de variable	Función linealizada
$y = \frac{a}{x} + b$	$x' = \frac{1}{x}, y' = y$	$y = a\frac{1}{x} + b$
$y = \frac{d}{x+c}$	$x' = x\,y, y' = y$ $c = -\frac{1}{a}, d = -\frac{b}{a}$	$y = -\frac{1}{c}(x\,y) + \frac{d}{c}$
$y = \frac{1}{ax+b}$	$x' = x, y' = \frac{1}{y}$	$\frac{1}{y} = ax + b$
$y = \frac{x}{a+bx}$	$x' = \frac{1}{x}$ $y' = \frac{1}{y}$	$\frac{1}{y} = a\frac{1}{x} + b$
$y = a\ln(x) + b$	$x' = \ln(x), y' = y$	$y = a\ln(x) + b$
$y = ce^{ax}$	$x' = x, y' = \ln(y)$ $c = e^b$	$\ln(y) = ax + \ln(c)$
$y = cx^a$	$x' = \ln(x), y' = \ln(y)$ $c = e^b$	$\ln(y) = a\ln(x) + \ln(c)$
$y = \frac{1}{(ax+b)^2}$	$x' = x$ $y' = \frac{1}{\sqrt{y}}$	$\frac{1}{\sqrt{y}} = ax + b$
$y = cxe^{-dx}$	$x' = x, y' = \ln(\frac{y}{x})$ $c = e^b, d = -a$	$\ln(\frac{y}{x}) = -dx + \ln(c)$
$y = \frac{m}{1+ce^{ax}}$	$x' = x, y' = \ln(\frac{m}{y} - 1)$ $c = e^b, m =$constant	$\ln(\frac{m}{y} - 1) = ax + \ln(c)$

Tabla 4: Cambio de variables en algunas funciones linealizables

2.4.10. Ejemplo

La tabla siguiente indica la cantidad de horas anuales que los un grupo de alumnos dedicó al desarrollo de ejercicios prácticos de la asignatura. Además, indica la calificación final obtenida en una escala de 1 a 5.

Estudiante	Horas	Calificación
1	40	4
2	42	4
3	30	3
4	35	3
5	25	1
6	28	2
7	32	3
8	35	3
9	40	4
10	42	4

Tabla 5: Datos de Horas de práctica y Calificación

a) Identifica e indica la variable dependiente y la independiente.
b) Realiza un gráfico de dispersión de los datos e indica la recta de ajuste.
c) Estima la recta de regresión lineal simple por mínimos cuadrados
d) Realiza la predicción de calificación final de un estudiante que dedica 24 horas de estudio de la materia.
e) Calcula el coeficiente de correlación lineal e interpreta su resultado.
f) Calcula el coeficiente de determinación e interpreta su resultado.
g) Calcula el valor del error estándar de la estimación

Solución

a) La calificación final de la materia matemática depende de la cantidad de horas anuales que dedicamos al estudio de la misma. Así que definimos las variables de la siguiente manera:

$X =$ variable independiente = cantidad de horas anuales

$Y =$ variable dependiente = calificación final

b) Una vez definidas las variables, cada observación es un punto (X,Y) que graficamos en el plano cartesiano.

X	Y
40	4
42	4
30	3
35	3
25	1
28	2
32	3
35	3
40	4
42	4

Tabla 6: Puntos (x,y) de horas y calificación

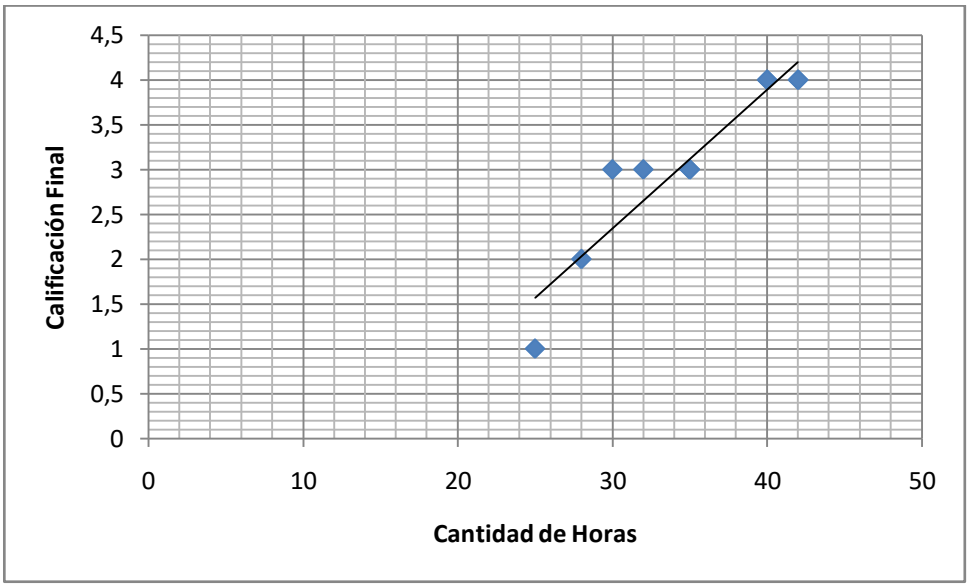

Figura 4: Relación entre Cantidad de horas y Calificación Final

c) Para hallar la recta de regresión $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$ debemos calcular los valores de $\hat{\beta}_0$ y $\hat{\beta}_1$ con las ecuaciones que establecimos según el método de mínimos cuadrados.

Comenzamos con $\hat{\beta}_1 = \dfrac{\sum_{i=1}^{n} X_i Y_i - \dfrac{\sum_{i=1}^{n} X_i \sum_{i=1}^{n} Y_i}{n}}{\sum_{i=1}^{n} X_i^2 - \dfrac{\left(\sum_{i=1}^{n} X_i\right)^2}{n}}$. Para obtener todos los datos que requiere la fórmula, completamos la siguiente tabla

X	Y	XY	X^2	Y^2
40	4	$40\times 4=160$	$40^2=1600$	16
42	4	$42\times 4=168$	$42^2=1764$	16
30	3	90	900	9
35	3	105	1225	9
25	1	25	625	1
28	2	56	784	4
32	3	96	1024	9
35	3	105	1225	9
40	4	160	1600	16
42	4	168	1764	16
$\sum_1^{10} X = 349$	$\sum_1^{10} Y = 31$	$\sum_1^{10} X.Y = 1133$	$\sum_1^{10} X^2 = 12511$	$\sum_1^{10} Y^2 = 105$

Tabla 7: Cálculos auxiliares de horas y calificación

Luego podemos calcular

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} X_i Y_i - \frac{\sum_{i=1}^{n} X_i \sum_{i=1}^{n} Y_i}{n}}{\sum_{i=1}^{n} X_i^2 - \frac{\left(\sum_{i=1}^{n} X_i\right)^2}{n}} = \frac{1133 - \frac{349\times 31}{10}}{12511 - \frac{(349)^2}{10}} \qquad \hat{\beta}_1 = 0{,}1544$$

Como $\hat{\beta}_0 = \overline{Y} - \beta_1 \overline{X}$, primero calculamos $\overline{Y} = \frac{\sum_1^{10} Y_i}{n} = \frac{31}{10} = 3{,}1$, y

$\overline{X} = \frac{\sum_1^{10} X_i}{n} = \frac{349}{10} = 34{,}9$.

Entonces $\hat{\beta}_0 = 3{,}1 - 0{,}1544\times 34{,}9$ $\qquad \hat{\beta}_0 = -2{,}2895$

La recta de regresión de mínimos cuadrados es $\hat{y} = -2{,}2895 + 0{,}1544x$

d) La recta $\hat{y} = -2{,}2895 + 0{,}1544x$ sirve para estimar la calificación final del estudiante que dedica $x = 24$ horas anuales a la asignatura.

$\hat{y} = -2{,}2895 + 0{,}1544\times 24$ $\qquad \hat{y} = 1{,}4161$

La calificación final es 1, si redondeamos la cifra a entero.

e) Para calcular el coeficiente de correlación lineal, usaremos los datos calculados en la tabla de cálculos auxiliares en la ecuación que establecimos el mismo.

$$r = \frac{n.\sum xy - \left(\sum x\right).\left(\sum y\right)}{\sqrt{\left[n.\sum x^2 - \left(\sum x\right)^2\right]\left[n.\sum y^2 - \left(\sum y\right)^2\right]}}, \quad r = \frac{10.(1133) - (349).(31)}{\sqrt{\left[10.(12511) - (349)^2\right]\left[10.(105) - (31)^2\right]}}$$

$$r = 0{,}9416$$

Como $r = 0{,}9416$ es positivo, las variables cantidad de horas y calificación final tienen una relación directa, decimos también que la relación lineal es fuerte porque el valor calculado es muy cercano a 1.

f) Obtenemos el coeficiente de determinación, elevando al cuadrado el coeficiente de correlación calculado:

$$r^2 = (0{,}9416)^2$$
$$r^2 = 0{,}8866$$

El 88,66% de la variabilidad de la calificación final es explicado por la recta de regresión estimada tomando cantidad de horas como variable explicativa.

g) Para el cálculo del error estándar necesitamos calcular cada valor estimado con nuestra ecuación $\hat{y} = -2{,}2895 + 0{,}1544x$.

X= x	Y= y	$\hat{y} = -2{,}2895 + 0{,}1544x$	$y - \hat{y}$	$\left(y - \hat{y}\right)^2$
40	4	$\hat{y} = -2{,}2895 + 0{,}1544 \times 40$ = 3,8865	$4 - 3{,}8865$ = 0,1135	0,01288225
42	4	$\hat{y} = -2{,}2895 + 0{,}1544 \times 42$ = 4,1953	$4 - 4{,}1953$ = -0,1953	0,03814209
30	3	2,3425	0,6575	0,43230625
35	3	3,1145	-0,1145	0,01311025
25	1	1,5705	-0,5705	0,32547025
28	2	2,0337	-0,0337	0,00113569
32	3	2,6513	0,3487	0,12159169
35	3	3,1145	-0,1145	0,01311025

40	4	3,8865	0,1135	0,01288225
42	4	4,1953	-0,1953	0,03814209
				$\sum\left(y-\hat{y}\right)^2 =$ 1,00877306

Tabla 8: Estimaciones y Error

Como $s_{y.x} = \sqrt{\dfrac{\sum\left(y-\hat{y}\right)^2}{n-2}}$, entonces $s_{y.x} = \sqrt{\dfrac{1{,}00877306}{10-2}}$, el valor del error estándar de la estimación es $s_{y.x} = 0{,}3551$

2.4.11. Ejemplo

Dada la siguiente tabla de dispersión,

x	0	1	2
y	1	2	6

Tabla 9: Puntos (x,y)

Determinar la función $y = c_1.e^{c_2 x}$ que mejor se ajusta a los puntos dados.

<u>Solución</u>

Veamos que la función solicitada no es lineal pero es linealizable, por lo que tendremos que realizar cambios de variables para obtener los parámetros necesarios (c_1, c_2).

Sea $y = c_1.e^{c_2 x}$, entonces $lny = ln(c_1.e^{c_2 x}) = lnc_1 + ln(e^{c_2 x}) = lnc_1 + c_2 x$.

Sean $z = lny$ y $k = lnc_1$, entonces la función linealizada es: $z = k + c_2 x$.

Construyamos la tabla de mínimos cuadrados, de manera a obtener los valores de k y de c_2.

x_i	y_i	$z_i = lny_i$	$x_i.z_i$	$(x_i)^2$
0	1	0	0	0
1	2	0.693	0.693	1
2	6	1.792	3.584	4
$\sum x_i = 3$	$\sum y_i = 9$	$\sum z_i = 2.485$	$\sum x_i.z_i = 4.277$	$\sum (x_i)^2 = 5$

Tabla 10: Cálculos auxiliares para la obtención de la función linealizada

Comenzamos calculando $c_2 = \dfrac{\sum_{i=1}^{n} x_i z_i - \dfrac{\sum_{i=1}^{n} x_i \sum_{i=1}^{n} z_i}{n}}{\sum_{i=1}^{n} (x_i)^2 - \dfrac{\left(\sum_{i=1}^{n} x_i\right)^2}{n}} = \dfrac{(4.277) - \dfrac{(3)(2.45)}{3}}{5 - \dfrac{3^2}{3}} = \boxed{0.9135}$

Ahora calculemos $k = \bar{z} - c_2 \bar{x}$

Necesitamos calcular previamente $\bar{z} = \dfrac{\sum_{i=1}^{n} z_i}{n} = \dfrac{2.485}{3} = 0.828$ y $\bar{x} = \dfrac{\sum_{i=1}^{n} x_i}{n} = \dfrac{3}{3} = 1$

Luego tenemos que $k = 0.828 - (0.9135).1 = \boxed{-0.0855}$

Ahora solo falta calcular c_1 para poder obtener la función solicitada.

Dijimos que $k = lnc_1$ entonces $\boxed{c_1 = e^k = e^{-0.0855} = 0.918}$

Finalmente tenemos que $\boxed{y = c_1 . e^{c_2 x} = (0.918). e^{0.9135 x}}$

2.5. MODELOS DE PRONÓSTICOS DE SERIES DE TIEMPO

Una serie de tiempo se basa en una secuencia de datos igualmente espaciados (semanales, mensuales, trimestrales, etcétera). Pronosticar con datos de series de tiempo implica que se predicen valores futuros tan solo a partir de datos históricos de esa variable y que se ignoran otras variables, sin importar su valor potencial.

2.5.1. Componentes de una serie de tiempo

Analizar una serie de tiempo significa desglosar los datos históricos en sus componentes y, luego, proyectarlos hacia el futuro. En general, una serie de tiempo tiene cuatro componentes:

1. Tendencia (T) es el movimiento gradual hacia arriba o hacia abajo de los datos en el tiempo.

2. Estacionalidad (S, por seasonality) es el patrón de la fluctuación de la demanda arriba o abajo de la recta de tendencia que se repite a intervalos regulares.

3. Ciclos (C) son patrones en los datos anuales que ocurren cada cierto número de años. Suelen estar vinculados al ciclo de negocios.

4. Variaciones aleatorias (R por Random variations) son "saltos" en los datos ocasionados por el azar y por situaciones inusuales; no siguen un patrón discernible.

Existen dos formas generales de los modelos de series de tiempo. La primera es un modelo multiplicativo que supone que la demanda es el producto de las cuatro componentes y se establece como:

$$Demanda = T\ x\ S\ x\ C\ x\ R$$

Un modelo aditivo suma las componentes para dar una estimación. Con frecuencia se usa un modelo de regresión múltiple para desarrollar los modelos aditivos. Esta relación aditiva se establece como:

$$Demanda = T + S + C + R$$

Hay otros modelos que pueden ser una combinación de estos. Por ejemplo, una de las componentes (como la tendencia) puede ser aditiva, en tanto que otra (como la estacionalidad) puede ser multiplicativa.

Entender las componentes de una serie de tiempo ayudará a seleccionar una técnica de pronósticos adecuada. Si todas las variaciones en una serie de tiempo se deben a variaciones aleatorias, sin componentes de tendencia, estacional o cíclica, se recomienda algún tipo de modelo de promedios o de suavizamiento. Las técnicas de promedios en esta sección son promedios móviles, promedio móvil ponderado y suavizamiento exponencial. Estos métodos suavizarán los pronósticos y no tendrán demasiada influencia de las variaciones aleatorias. Sin embargo, si hay en los datos un patrón de tendencia o estacional, entonces, se debería usar una técnica que incorpore esa componente en particular en el pronóstico. Dos de tales técnicas son el suavizamiento exponencial con tendencia y las proyecciones de tendencia. Si existe un patrón estacional presente en los datos, podría desarrollarse un índice estacional y usarse con cualquier método de promedios. Si están

presentes las componentes de tendencia y estacional, entonces, deberá emplearse un método como el de descomposición.

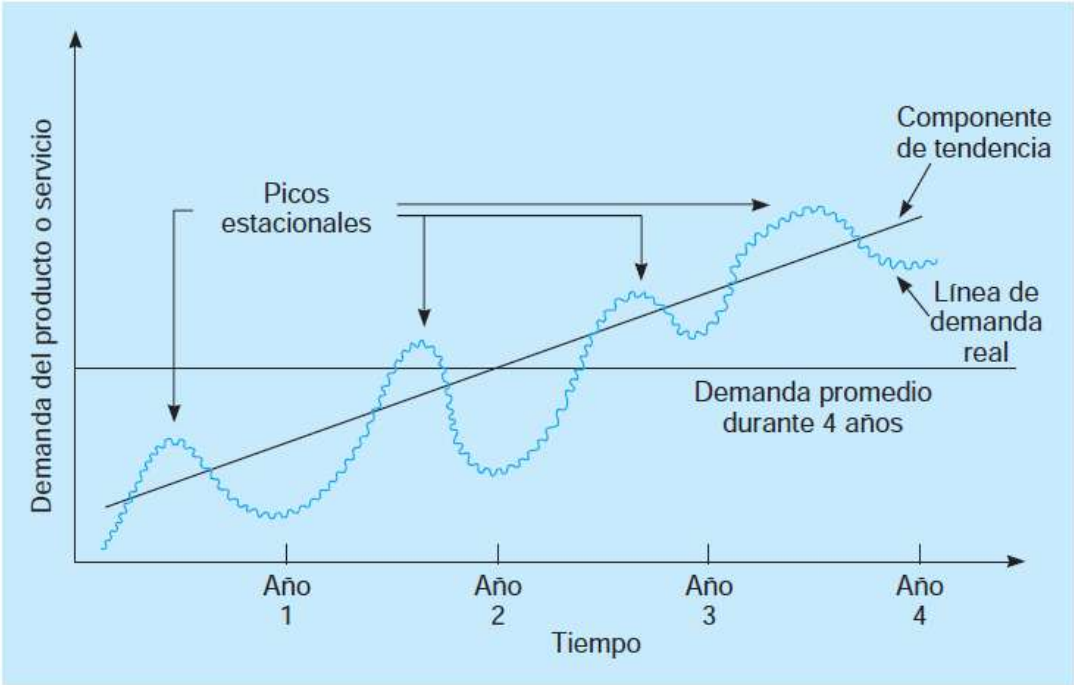

Figura 5: Demanda de productos graficada para 4 años, con tendencia y estacionalidad

2.5.2. Suavizamiento exponencial con ajuste de tendencia

Las técnicas para promediar o suavizar el pronóstico son útiles cuando una serie de tiempo tiene tan solo una componente aleatoria; sin embargo, tales técnicas no responden a las tendencias. Si hay una tendencia presente en los datos, debería usarse un modelo de pronóstico que la incorpore de manera explícita en el pronóstico. Una de esas técnicas es el modelo de suavizamiento exponencial con ajuste de tendencia. La idea es desarrollar un pronóstico de suavizamiento exponencial y, luego, ajustarlo por la tendencia. Se emplean dos constantes de suavizamiento, α y β , en este modelo y ambos valores deben estar entre 0 y 1. El nivel del pronóstico se ajusta multiplicando primero la constante de suavizamiento, α, por el error del pronóstico más reciente y sumarlo al pronóstico anterior. La tendencia se ajusta multiplicando la segunda constante de suavizamiento, β, por el error más reciente o la cantidad en exceso de la tendencia. Un valor más alto da más peso a las observaciones recientes y, con ello, responde con mayor rapidez a los cambios en los patrones. Al igual que con el suavizamiento

exponencial simple, la primera vez que se desarrolla un pronóstico, debe darse o estimarse un pronóstico anterior (F_t). Si no se dispone de uno, con frecuencia se supone que el pronóstico inicial es perfecto. Asimismo, debe darse o estimarse una tendencia previa (T_t), que muchas veces se estima usando otros datos históricos, si están disponibles, o bien, utilizando medios subjetivos o calculando el incremento (o decremento) observado durante los primeros periodos de los datos disponibles. Sin esa estimación disponible, en ocasiones se supone que la tendencia es 0 inicialmente, aunque podría llevar a pronósticos deficientes, si la tendencia es grande y es pequeño. Una vez establecidas las condiciones iniciales, se desarrolla el pronóstico de suavizamiento exponencial incluyendo la tendencia (FIT_T) mediante los siguientes tres pasos:

Paso 1. Calcular el pronóstico suavizamiento (F_{t+1}) para el periodo $t+1$ usando la ecuación

$$Pronóstico\ suavizamiento = \ pronóstico\ previo\ incluyendo\ tendencia + \alpha(último\ error)$$

$$F_{t+1} = FIT_t + \alpha(Y_t - FIT_t)$$

Paso 2. Actualizar la tendencia (T_{t+1}) con la ecuación

$$Tendencia\ suavizada = \ tendencia\ previa + \beta(error\ o\ exceso\ de\ tendencia)$$

$$T_{t+1} = T_t + \beta(F_{t+1} - FIT_t)$$

Paso 3. Calcular el pronóstico de suavizamiento exponencial ajustado por la tendencia (FIT_{t+1}) usando la ecuación

$$Pronóstico\ con\ tendencia\ (FITt_{t+1}) = \ pronóstico\ suavizamiento\ (F_{t+1}) + \ tendencia\ suavizada\ (T_{t+1})$$

$$FIT_{t+1} = F_{t+1} + T_{t+1}$$

Donde

$T_t =$ tendencia suavizada para el periodo t

$F_t =$ pronóstico suavizamiento para el periodo t

$FIT_t =$ Pronóstico incluyendo tendencia para el periodo t

$\alpha =$ constante de suavizamiento para el pronóstico

$\beta =$ constante de suavizamiento para la tendencia

2.5.2.1. Ejemplo

Consideremos el caso de la compañía Midwestern Manufacturing que, en el periodo de 2004 a 2010, ha tenido la demanda de generadores eléctricos que se presenta en la tabla de abajo. Para usar el método de suavizamiento

exponencial con ajuste de tendencia, primero se establecen las condiciones iniciales (valores previos para F y T), y se eligen α y β . Suponiendo que F_1 es perfecto y T_1 es 0, y eligiendo 0.3 y 0.4 como las constantes de suavizamiento, respectivamente, seguir los pasos pertinentes para obtener los pronósticos con ajuste de tendencia de los años dados en la tabla.

AÑO	GENERADORES ELÉCTRICOS VENDIDOS
2004	74
2005	79
2006	80
2007	90
2008	105
2009	142
2010	122

Tabla 11: Demanda de Midwestern Manufacturing

Solución

Sean $F_1 = 74$, $T_1 = 0$, $\alpha = 0.3$, $\beta = 0.4$, lo cual da como resultado:

$$FIT_1 = F_1 + T_1 = 74 + 0 = 74$$

Siguiendo los tres pasos para obtener el pronóstico para 2005 (periodo 2), tenemos

Paso 1. Calcular F_{t+1} con la ecuación

$$F_{t+1} = FIT_t + \alpha(Y_t - FIT_t)$$

$$F_2 = FIT_1 + 0.3(Y_1 - FIT_1) = 74 + 0.3(74 - 74) = 74$$

Paso 2. Actualizar la tendencia (T_{t+1}) usando la ecuación

$$T_{t+1} = T_t + \beta(F_{t+1} - FIT_t)$$

$$T_2 = T_1 + 0.4(F_2 - FIT_1) = 0 + 0.4(74 - 74) = 0$$

Paso 3. Calcular el pronóstico de suavizamiento exponencial de ajuste de tendencia (FIT_{t+1}) usando la ecuación

$$FIT_{t+1} = F_{t+1} + T_{t+1}$$

$$FIT_2 = F_2 + T_2 = 74 + 0 = 74$$

Para 2006 (periodo 3), tenemos

Paso 1.

$$F_3 = FIT_2 + 0.3(Y_2 - FIT_2) = 74 + 0.3(79 - 74) = 75.5$$

Paso 2.

$$T_3 = T_2 + 0.4(F_3 - FIT_2) = 0 + 0.4(75.5 - 74) = 0.6$$

Paso 3.

$$FIT_3 = F_3 + T_3 = 75.5 + 0.6 = 76.1$$

Los otros resultados se muestran en la tabla siguiente. El pronóstico para 2011 sería de aproximadamente 131.35.

TIEMPO (t)	DEMANDA (Y_t)	$F_{t+1} = FIT_t + 0.3(Y_t - FIT_t)$	$T_{t+1} = T_t + 0.4(F_{t+1} - FIT_t)$	$FIT_{t+1} = F_{t+1} + T_{t+1}$
1	74	74	0	74
2	79	74 = 74 + 0.3(74 − 74)	0 = 0 + 0.4(74 − 74)	74 = 74 + 0
3	80	75.5 = 74 + 0.3(79 − 74)	0.6 = 0 + 0.4(75.5 − 74)	76.1 = 75.5 + 0.6
4	90	77.270 = 76.1 + 0.3(80 − 76.1)	1.068 = 0.6 + 0.4(77.27 − 76.1)	78.338 = 77.270 + 1.068
5	105	81.837 = 78.338 + 0.3(90 − 78.338)	2.468 = 1.068 + 0.4(81.837 − 78.338)	84.305 = 81.837 + 2.468
6	142	90.514 = 84.305 + 0.3(105 − 84.305)	4.952 = 2.468 + 0.4(90.514 − 84.305)	95.466 = 90.514 + 4.952
7	122	109.426 = 95.466 + 0.3(142 − 95.466)	10.536 = 4.952 + 0.4(109.426 − 95.466)	119.962 = 109.426 + 10.536
8		120.573 = 119.962 + 0.3(122 − 119.962)	10.780 = 10.536 + 0.4(120.573 − 119.962)	131.353 = 120.573 + 10.780

Tabla 12: Pronósticos con suavizamiento exponencial con tendencia para Midwestern Manufacturing

2.5.2.2. Precisión del pronóstico.

Una consideración importante en la selección de un método de elaboración de pronósticos es la precisión del pronóstico. Desde luego, queremos pronosticar que los errores sean menores. El Error Cuadrado Medio (ECM) es una medida de uso frecuente de la precisión de un método de elaboración de pronósticos. Se obtiene calculando el promedio de los cuadrados de los errores.

Otra manera de medir la precisión es calculando la DMA de los errores, lo cual ya se había desarrollado con anterioridad.

2.5.3. Proyección de la tendencia

En esta sección mostramos cómo pronosticar los valores de una serie de tiempo que exhibe una tendencia lineal a largo plazo. El tipo de series de tiempo para las cuales el método de proyección de tendencias es aplicable, muestra un incremento o disminución constante en el tiempo. Debido a que

este tipo de serie de tiempo no es estable, los métodos de suavización descritos en la sección anterior no son aplicables.

2.5.3.1. Ejemplo

Consideremos la serie de tiempo para la venta de bicicletas de un fabricante en particular durante los 10 años anteriores, como muestran la tabla y la figura de abajo.

Año (t)	Ventas (miles) (Y_t)
1	21.6
2	22.9
3	25.5
4	21.9
5	23.9
6	27.5
7	31.5
8	29.7
9	28.6
10	31.4

Tabla 13: Serie de tiempo de las ventas de bicicletas

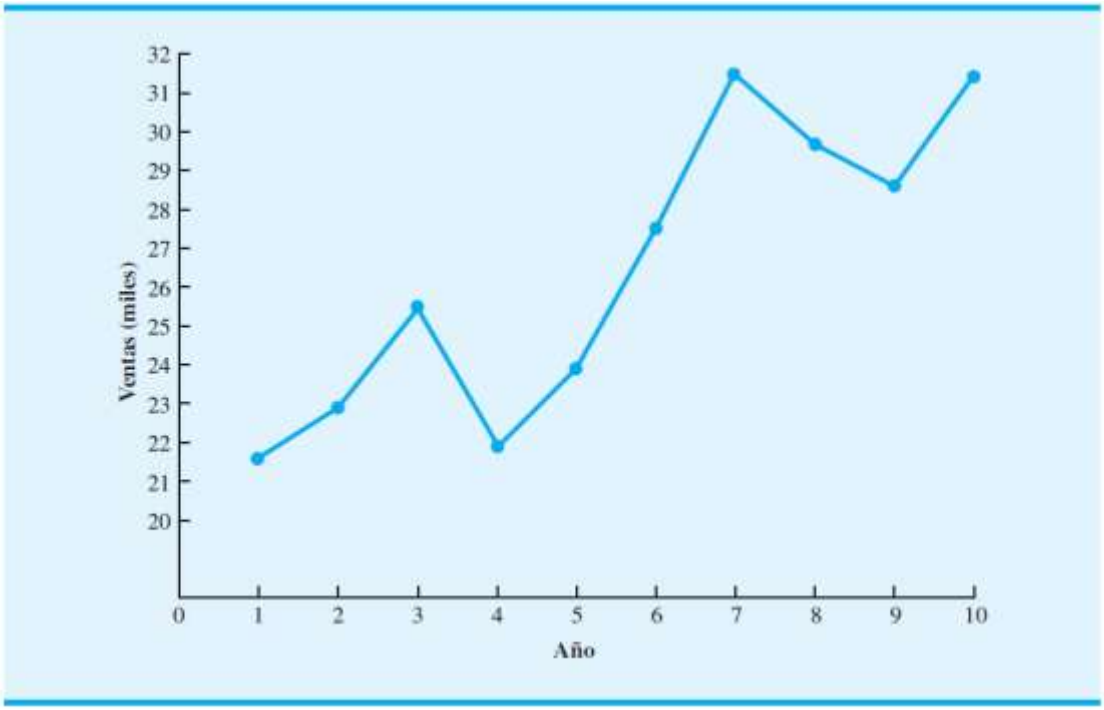

Figura 6: Gráfica de las series de tiempo de las ventas de bicicletas

Veamos que se vendieron 21,600 bicicletas en el año 1; 22,900 en el año 2, etc. En el año 10, el año más reciente, se vendieron 31,400 bicicletas. Aunque la figura muestra cierto movimiento ascendente y descendente durante los 10 años anteriores, la serie de tiempo para el número de bicicletas vendidas

parece tener un incremento general o una tendencia ascendente. No queremos que el componente de tendencia de una serie de tiempo siga cada uno y todos los movimientos "ascendentes" y "descendentes". En vez de ello, el componente de tendencia debe reflejar el cambio gradual, en este caso el crecimiento, de los valores de la serie de tiempo. Después de ver los datos de la serie de tiempo de la tabla y la gráfica de la figura, podríamos estar de acuerdo en que una tendencia lineal como muestra la figura siguiente, proporciona una descripción razonable del movimiento a largo plazo de la serie.

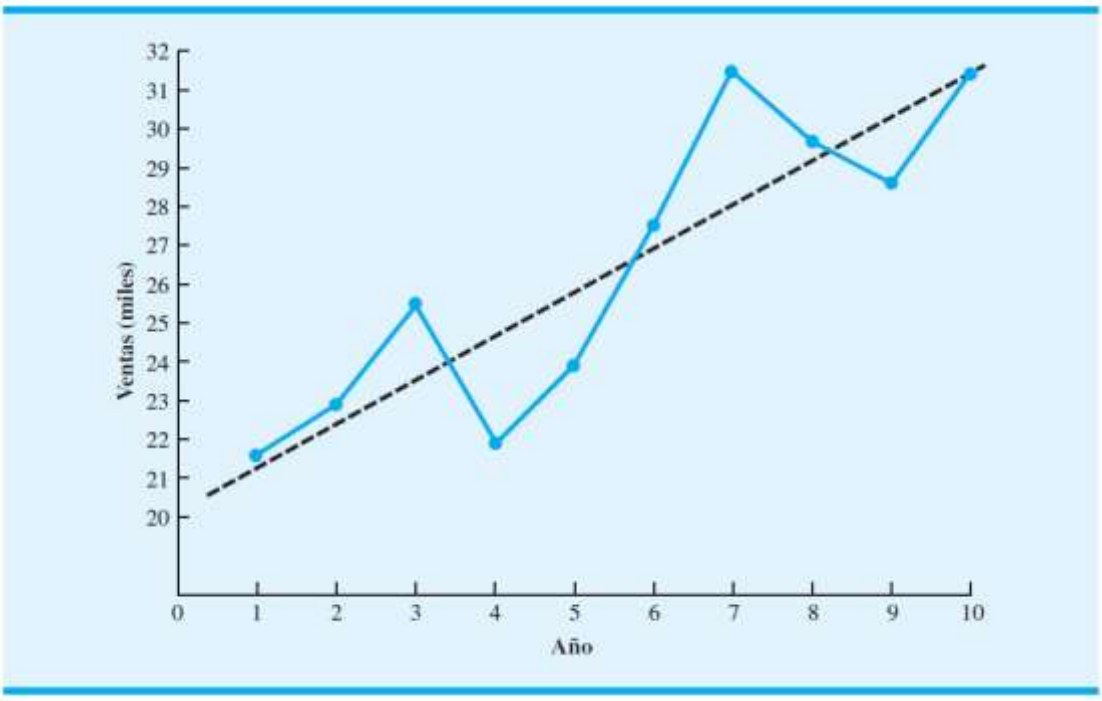

Figura 7: Tendencia representada por una función lineal para las ventas de bicicletas

Utilizamos los datos de las ventas de bicicletas para ilustrar los cálculos involucrados en la aplicación del análisis de regresión con el fin de identificar una tendencia lineal. Para una tendencia lineal, el volumen de ventas estimado expresado como una función del tiempo es:

$$T_t = \hat{\beta}_0 + \hat{\beta}_1 t$$

Donde:

$T_t =$ valor de tendencia para las ventas de bicicletas en el periodo t

$\hat{\beta}_0 =$ intercepto de la línea de tendencia

$\hat{\beta}_1 =$ pendiente de la línea de tendencia

Observemos que, para la serie de tiempo de las ventas de bicicletas, $t = 1$ corresponde al valor más antiguo de la serie de tiempo, y $t = 10$ corresponde al valor más reciente de la serie de tiempo. Las ecuaciones para calcular $\hat{\beta}_0$ y $\hat{\beta}_1$ ya se han estudiado en la sección de regresión lineal simple.

Para este caso particular haremos el proceso para obtener la ecuación de la recta de tendencia por ajuste lineal de mínimos cuadrados. Explicaremos lo que significa el valor de la pendiente de la recta y pronosticaremos el valor de las ventas para los años 11, 12 y 13.

Solución

Primeramente construyamos la tabla necesaria para calcular los valores de $\hat{\beta}_0$ y $\hat{\beta}_1$ de la recta de tendencia.

	t	Y_t	tY_t	t^2
	1	21.6	21.6	1
	2	22.9	45.8	4
	3	25.5	76.5	9
	4	21.9	87.6	16
	5	23.9	119.5	25
	6	27.5	165.0	36
	7	31.5	220.5	49
	8	29.7	237.6	64
	9	28.6	257.4	81
	10	31.4	314.0	100
Totales	55	264.5	1545.5	385

Tabla 14: Cálculos auxiliares para la recta de tendencia

Entonces los coeficientes de la recta de tendencia son:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} t_i Y_i - \frac{\sum_{i=1}^{n} t_i \sum_{i=1}^{n} Y_i}{n}}{\sum_{i=1}^{n} t_i^2 - \frac{\left(\sum_{i=1}^{n} t_i\right)^2}{n}} = \frac{(1545.5) - \frac{(55)(264.5)}{10}}{385 - \frac{55^2}{10}} = \boxed{1.1}$$

Como $\hat{\beta}_0 = \bar{Y} - \beta_1 \bar{t}$, primero calculamos $\bar{Y} = \frac{\sum_1^{10} Y_i}{n} = \frac{264.5}{10} = \boxed{26.45}$, y $\bar{t} = \frac{\sum_1^{10} t_i}{n} = \frac{55}{10} = \boxed{5.5}$. Luego, $\hat{\beta}_0 = \bar{Y} - \beta_1 \bar{t} = 26.45 - (1.1)(5.5) = \boxed{20.4}$

Finalmente la recta de tendencia es:

$$\boxed{T_t = \hat{\beta}_0 + \hat{\beta}_1 t = 20.4 + 1.1t}$$

La pendiente de 1.1 en la ecuación de tendencia indica que durante los 10 años pasados la empresa ha experimentado un crecimiento medio en las ventas de alrededor de 1100 unidades por año. Si suponemos que la tendencia de los 10 años pasados en ventas es un buen indicador para el futuro, podemos utilizar la ecuación de la recta obtenida, para proyectar el componente de tendencia de la serie de tiempo. Por ejemplo, al sustituir $t = 11$ en la ecuación obtenemos la proyección de tendencia del año siguiente, T_{11}:

$$T_{11} = 20.4 + (1.1)(11) = 32.5$$

Por tanto, el componente de tendencia produce un pronóstico de ventas de 32,500 bicicletas para el año siguiente.

También podemos utilizar la línea de tendencia para pronosticar las ventas en un futuro más lejano. Por ejemplo, con la ecuación elaboramos pronósticos para dos y tres años adicionales en el futuro como sigue:

$$T_{12} = 20.4 + (1.1)(12) = 33.6$$

$$T_{13} = 20.4 + (1.1)(13) = 34.7$$

2.5.4. Componentes de tendencia y estacional

Mostramos cómo pronosticar los valores de una serie de tiempo que tienen un componente de tendencia. En esta sección ampliamos la explicación al indicar cómo pronosticar los valores de una serie de tiempo que tiene tanto un componente de tendencia como uno estacional.

Numerosas situaciones en los negocios y la economía involucran comparaciones de un periodo a otro. Por ejemplo, podríamos estar interesados en saber que la tasa de desempleo aumentó 2% en comparación

con el último mes, la producción de acero aumentó 5% con respecto al mes pasado, o la producción de energía eléctrica disminuyó 3% a diferencia del mes anterior. Sin embargo, se debe tener sumo cuidado al utilizar esta información, debido a que siempre que existe una influencia estacional, estas comparaciones por lo general no son especialmente significativas. Por ejemplo, el hecho de que el consumo de energía eléctrica disminuyó 3%, de agosto a septiembre, podría ser el único efecto estacional asociado con un incremento en el uso del aire acondicionado y no deberse a una disminución a largo plazo en el uso de la electricidad. En efecto, después de ajustarnos al efecto estacional, podríamos encontrar incluso que el uso de la energía eléctrica ha aumentado. La eliminación del efecto estacional de una serie de tiempo se conoce como *desestacionalización de la serie de tiempo*. Después de hacerlo, las comparaciones periodo a periodo son más significativas y pueden ayudar a identificar si existe una tendencia. El enfoque que seguimos en esta sección es apropiado en situaciones cuando sólo están presentes los efectos estacionales o en situaciones en que se dan tanto el componente estacional como el de tendencia. El primer paso es calcular los índices estacionales y utilizarlos para desestacionalizar los datos. Luego, si es evidente una tendencia en los datos desestacionalizados, utilizamos el análisis de regresión sobre los datos desestacionalizados para estimar la tendencia.

2.5.4.1. Modelo multiplicativo

Además de un componente de tendencia *T* y un componente estacional *S*, asumimos que la serie de tiempo también tiene un componente irregular *I*. El componente irregular representa los efectos aleatorios de la serie de tiempo que no pueden explicarse por medio de los componentes de tendencia y estacional. Con T_t, S_t e I_t para identificar los componentes de tendencia, estacional e irregular en el tiempo t, suponemos que el valor de la serie de tiempo real, denotado por Y_t, puede describirse por el **modelo multiplicativo de series de tiempo**.

$$Y_t = T_t \; x \; S_t \; x \; I_t$$

En este modelo, T_t es la tendencia medida en unidades del elemento que se pronostica. Sin embargo, los componentes S_t e I_t se miden en términos

relativos, con valores por encima de 1, lo que indica efectos por encima de la tendencia, y valores por debajo de 1 que denotan efectos por debajo de la tendencia.

2.5.4.2. Ejemplo

Los datos de la tabla de abajo muestran las ventas de televisores (en miles de unidades) para un fabricante en particular durante los cuatro años pasados.

Año	Trimestre	Ventas (en miles)
1	1	4.8
	2	4.1
	3	6.0
	4	6.5
2	1	5.8
	2	5.2
	3	6.8
	4	7.4
3	1	6.0
	2	5.6
	3	7.5
	4	7.8
4	1	6.3
	2	5.9
	3	8.0
	4	8.4

Tabla 15: Datos trimestrales para las ventas de televisores

La gráfica en serie de tiempo de los datos dados es:

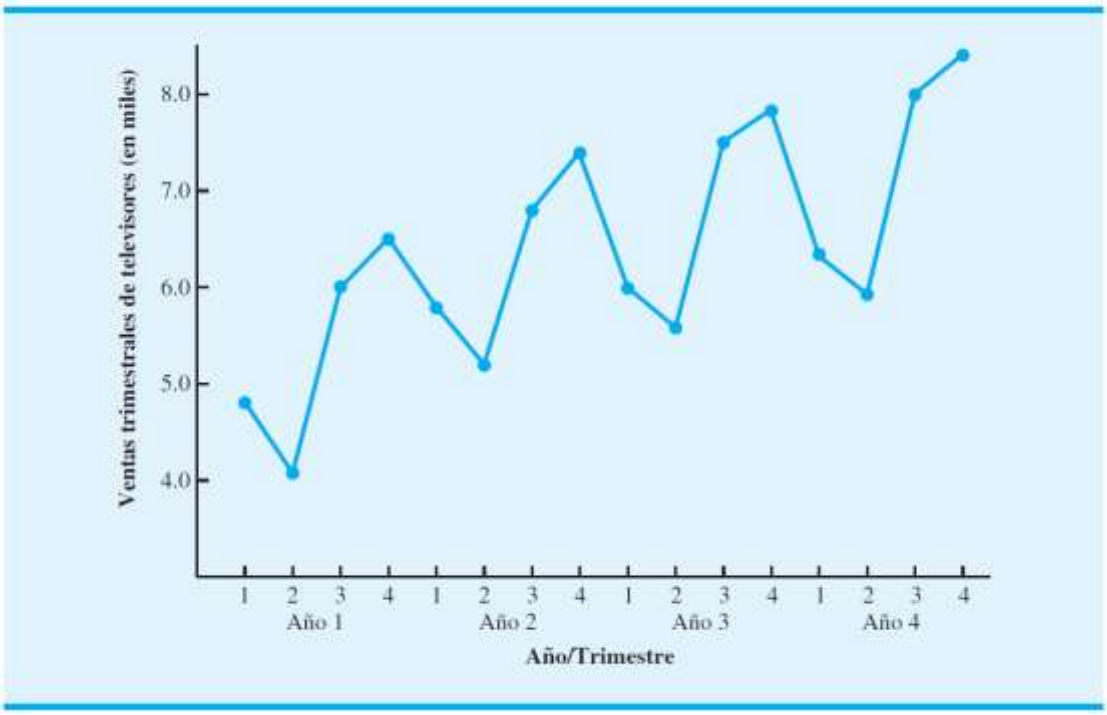

Figura 8: Gráfica de las series de tiempo de ventas trimestrales de los televisores

Solución

- **Cálculo de los índices estacionales**

La figura anterior indica que las ventas son menores en el segundo trimestre de cada año, seguidas por los niveles de ventas más altos en los trimestres 3 y 4. Por tanto, concluimos que existe un patrón estacional para las ventas de televisores. Comenzamos el procedimiento de cálculo utilizado para identificar la influencia estacional de cada trimestre al calcular un promedio móvil para aislar los componentes estacional e irregular, S_t e I_t. Para hacerlo, utilizamos datos de un año en cada cálculo. Como estamos trabajando con una serie trimestral, utilizamos cuatro valores de datos en cada promedio móvil. El cálculo del promedio móvil para los primeros cuatro trimestres de los datos de ventas de televisores es:

$$Primer\ promedio\ móvil = \frac{4.8 + 4.1 + 6 + 6.5}{4} = \frac{21.4}{4} = 5.35$$

Observemos que el cálculo del promedio móvil para los primeros cuatro trimestres produjo el promedio de ventas trimestrales durante un año de la serie de tiempo. Si continuamos con el cálculo del promedio móvil, luego se suma el valor de 5.8 para el primer trimestre del año 2 y se omite el 4.8 para el primer trimestre del año 1. Por tanto, el segundo promedio móvil es:

$$Segundo\ promedio\ móvil = \frac{4.1 + 6 + 6.5 + 5.8}{4} = \frac{22.4}{4} = 5.6$$

Antes de proseguir con los cálculos del promedio móvil para la serie de tiempo entera, regresamos al cálculo del primer promedio móvil, el cual dio como resultado un valor de 5.35, que representa un volumen medio de ventas trimestrales (en todas las temporadas) para el año 1. Cuando regresamos al cálculo del valor 5.35, tiene sentido asociar 5.35 con el trimestre “medio” del grupo de promedios móviles. Notemos, no obstante, que encontramos algunas dificultades para identificar el trimestre medio; cuatro trimestres en el promedio móvil no permiten un trimestre medio. El valor 5.35 corresponde a la última mitad del trimestre 2 y a la primera mitad del trimestre 3. De modo parecido, si pasamos al siguiente valor del promedio móvil de 5.60, la parte media corresponde a la última mitad del trimestre 3 y a la primera mitad del trimestre 4.

Recordemos que la razón para calcular promedios móviles es aislar los componentes estacional e irregular combinados. Sin embargo, los valores de los promedios móviles que calculamos no corresponden directamente a los trimestres originales de la serie de tiempo. Podemos resolver esta dificultad al utilizar los puntos medios entre los valores de promedios móviles sucesivos. Por ejemplo, como 5.35 corresponde a la primera mitad del trimestre 3 y 5.60 corresponde a la última mitad del trimestre 3, podemos utilizar $\frac{(5.35 + 5.60)}{2} = 5.475$ como el valor del promedio móvil para el trimestre 3.

Asimismo, asociamos un valor de promedio móvil de $\frac{(5.60 + 5.875)}{2} = 5.738$ con el trimestre 4. El resultado es un ***promedio móvil centrado***.

La tabla siguiente muestra un resumen completo de los cálculos del promedio móvil y del promedio móvil centrado para los datos de las ventas de televisores.

Año	Trimestre	Ventas (en miles)	Promedio móvil del cuarto trimestre	Promedio móvil centrado
1	1	4.8		
	2	4.1		
	3	6.0	5.350	5.475
	4	6.5	5.600	5.738
2	1	5.8	5.875	5.975
	2	5.2	6.075	6.188
	3	6.8	6.300	6.325
	4	7.4	6.350	6.400
3	1	6.0	6.450	6.538
	2	5.6	6.625	6.675
	3	7.5	6.725	6.763
	4	7.8	6.800	6.838
4	1	6.3	6.875	6.938
	2	5.9	7.000	7.075
	3	8.0	7.150	
	4	8.4		

Tabla 16: Cálculos del promedio móvil centrado para las series de tiempo de ventas de televisores

Si el número de puntos de datos en un cálculo de promedio móvil es un número impar, el punto medio corresponderá a uno de los periodos en la serie de tiempo. En estos casos no tendríamos que centrar los valores del promedio móvil para hacerlos corresponder con un periodo en particular.

La figura siguiente muestra gráficas de los valores de la serie de tiempo real y el promedio móvil centrado correspondiente. Observemos en particular cómo los valores del promedio móvil centrado tienden a "suavizar" las fluctuaciones tanto estacional como irregular en la serie de tiempo. Los valores del promedio móvil calculados para cuatro trimestres de datos no incluyen las fluctuaciones debidas a influencias estacionales porque el efecto estacional se ha promediado. Cada punto en el promedio móvil centrado representa cuál sería el valor de la serie de tiempo sin influencias estacionales o irregulares.

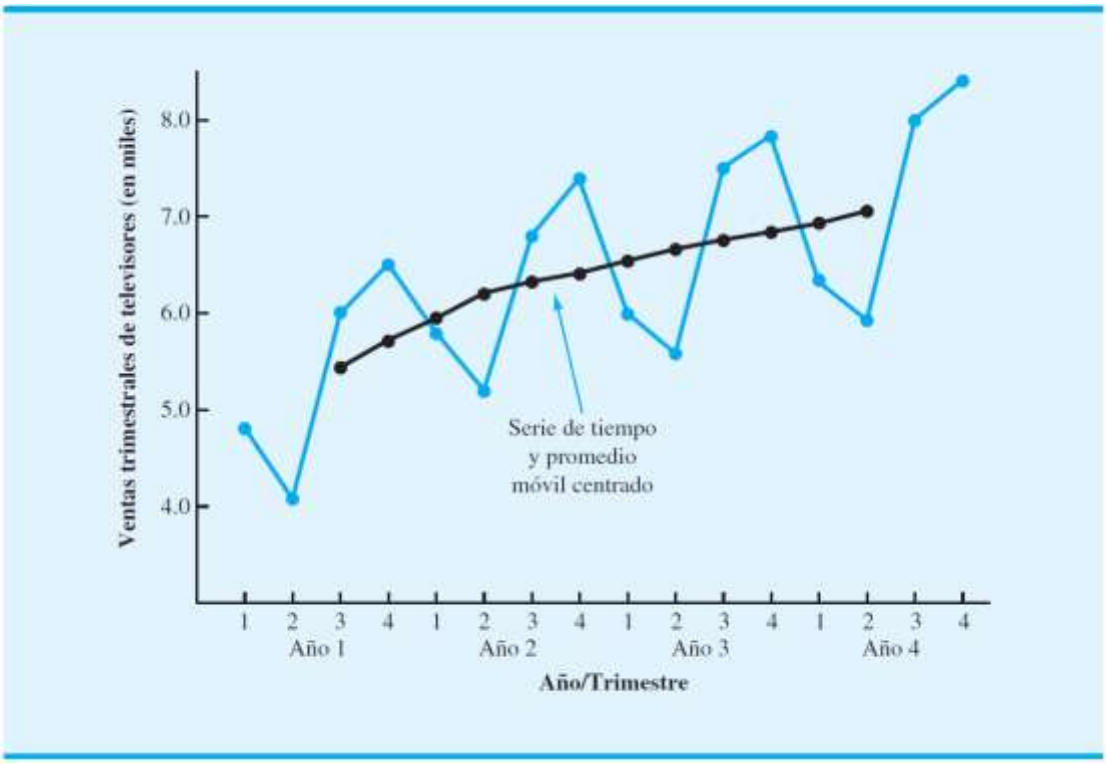

Figura 9: Gráfica de series de tiempo de las ventas trimestrales de televisores y del promedio móvil centrado

Al dividir cada observación de la serie de tiempo entre el valor del promedio móvil centrado correspondiente, podemos identificar el efecto estacional-irregular en la serie de tiempo. Por ejemplo, el tercer trimestre del año 1 muestra $\frac{6.0}{5.475} = 1.096$ como el componente estacional-irregular combinado. La tabla siguiente resume los valores estacionales – irregulares resultantes para toda la serie de tiempo.

Año	Trimestre	Ventas (en miles)	Promedio móvil centrado	Valores estacionales-irregulares
1	1	4.8		
	2	4.1		
	3	6.0	5.475	1.096
	4	6.5	5.738	1.133
2	1	5.8	5.975	0.971
	2	5.2	6.188	0.840
	3	6.8	6.325	1.075
	4	7.4	6.400	1.156
3	1	6.0	6.538	0.918
	2	5.6	6.675	0.839
	3	7.5	6.763	1.109
	4	7.8	6.838	1.141
4	1	6.3	6.938	0.908
	2	5.9	7.075	0.834
	3	8.0		
	4	8.4		

Tabla 17: Valores estacionales-irregulares para las series de tiempo de las ventas de televisores

Consideremos el tercer trimestre. Los resultados de los años 1, 2 y 3 muestran valores del tercer trimestre de 1.096, 1.075 y 1.109, respectivamente. Por tanto, en todos los casos el componente estacional-irregular parece tener una influencia por encima del promedio en el tercer trimestre. Las fluctuaciones durante los tres años pueden atribuirse al componente irregular, por lo que podemos promediar los valores calculados para eliminar la influencia irregular y obtener una estimación de la influencia estacional del tercer trimestre:

$$Efecto\ estacional\ del\ tercer\ trimestre = \frac{1.096 + 1.075 + 1.109}{3} = 1.09$$

Nos referimos a 1.09 como el **índice estacional** para el tercer trimestre. En la tabla siguiente se resumen los valores involucrados en el cálculo de los índices estacionales para las series de tiempo de ventas de televisores. Por tanto, los índices estacionales para los cuatro trimestres son: trimestre 1= 0.93; trimestre 2 = 0.84; trimestre 3 = 1.09 y trimestre 4 = 1.14.

Trimestre	Valores del componente estacional-irregular (S_tI_t)	Índice estacional (S_t)
1	0.971, 0.918, 0.908	0.93
2	0.840, 0.839, 0.834	0.84
3	1.096, 1.075, 1.109	1.09
4	1.113, 1.156, 1.141	1.14

Tabla 18: Cálculos del índice estacional para las series de tiempo de las ventas de televisores

La interpretación de los valores de la tabla 18 proporciona algunas observaciones sobre el componente "estacional" en las ventas de televisores. El trimestre de mejores ventas es el cuarto, con ventas que promedian 14% por encima del valor medio trimestral. El trimestre con peores ventas, o más lento, es el segundo, con un índice estacional de 0.84, que muestra que las ventas promediaron 16% por debajo de las ventas medias trimestrales. El componente estacional corresponde a la expectativa intuitiva de que el interés por ver televisión y, por tanto, los patrones de compra de televisores tienden a alcanzar valores máximos en el cuarto trimestre, ya que la temporada de invierno está próxima y hay menos actividades al aire libre (hemisferio norte). Las ventas bajas del segundo trimestre reflejan el interés reducido en la televisión como resultado de las actividades de primavera y previas al verano de los clientes potenciales (hemisferio norte).

Tal vez sea necesario un ajuste final para obtener los índices estacionales. El modelo multiplicativo requiere que el índice estacional medio sea igual 1.00, así que la suma de los cuatro índices estacionales de la tabla 18 debe ser igual a 4.00. En otras palabras, los efectos estacionales deben igualarse a lo largo del año. El promedio de los índices estacionales en nuestro ejemplo es igual a 1.00, y por ende este tipo de ajuste no es necesario.

En otros casos puede requerirse un ajuste ligero, para lo cual, multiplicaremos cada índice estacional por el número de estaciones dividido entre la suma de los índices estacionales sin ajustar. Por ejemplo, para los datos trimestrales, multiplique cada índice estacional por $\frac{4}{(suma\ \ de\ los\ índices\ \ estacionales\ \ \ sin\ ajustar\ )}$.

Esto es lo mismo que dividir cada índice estacional por el promedio de índices estacionales.

2.5.5. Desestacionalización de las series de tiempo

El propósito de determinar índices estacionales es precisamente eliminar los efectos estacionales de una serie de tiempo. Este proceso se conoce como ***desestacionalizacion*** de las series de tiempo.

Con la notación del modelo multiplicativo se obtiene

$$Y_t = T_t \; x \; S_t \; x \; I_t$$

Al dividir cada observación de serie de tiempo entre el índice estacional correspondiente se elimina el efecto estacional de la serie de tiempo. En la tabla siguiente se resume la serie de tiempo desestacionalizada para las ventas de televisores, y en la figura siguiente se muestra una gráfica de la serie de tiempo desestacionalizada de las ventas de televisores.

Año	Trimestre	Ventas (en miles) (Y_t)	Índice estacional (S_t)	Ventas desestacionalizadas ($Y_t/S_t = T_tI_t$)
1	1	4.8	0.93	5.16
	2	4.1	0.84	4.88
	3	6.0	1.09	5.50
	4	6.5	1.14	5.70
2	1	5.8	0.93	6.24
	2	5.2	0.84	6.19
	3	6.8	1.09	6.24
	4	7.4	1.14	6.49
3	1	6.0	0.93	6.45
	2	5.6	0.84	6.67
	3	7.5	1.09	6.88
	4	7.8	1.14	6.84
4	1	6.3	0.93	6.77
	2	5.9	0.84	7.02
	3	8.0	1.09	7.34
	4	8.4	1.14	7.37

Tabla 19: Valores desestacionalizados para las series de tiempo de las ventas de televisores

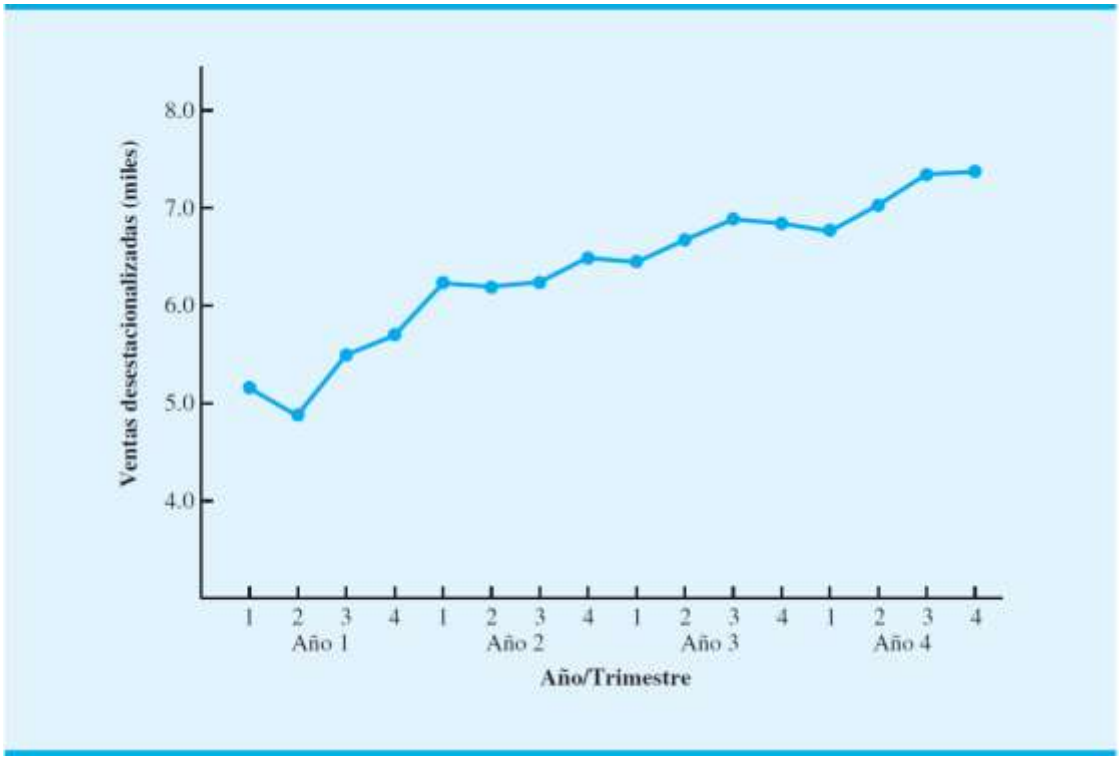

Figura 10: Series de tiempo desestacionalizadas de las ventas de televisores

2.5.5.1.1. Uso de series de tiempo desestacionalizadas para identificar tendencias

Aunque la gráfica de la fi gura 10 muestra cierto movimiento ascendente y descendente durante los 16 trimestres pasados, la serie de tiempo parece tener una tendencia lineal ascendente. Para identificar esta tendencia, utilizamos el mismo procedimiento que habíamos utilizado en la sección de **Proyección de la Tendencia**; en este caso, los datos utilizados son los valores de las ventas trimestrales desestacionalizadas. Por tanto, para una tendencia lineal, el volumen de ventas estimadas expresado como una función del tiempo es:

$$T_t = \hat{\beta}_0 + \hat{\beta}_1 t$$

donde

$T_t =$ valor de tendencia para las ventas de televisores en el periodo t

$\hat{\beta}_0 =$ intercepto de la línea de tendencia

$\hat{\beta}_1 =$ pendiente de la tendencia en el tiempo

Como antes, $t = 1$ corresponde al tiempo de la primera observación para la serie de tiempo, $t = 2$ corresponde al tiempo de la segunda observación, etc. Por tanto, para las series de tiempo de las ventas desestacionalizadas de televisores, $t = 1$ corresponde al primer valor de las ventas trimestrales desestacionalizadas y $t = 16$ corresponde al valor de ventas trimestrales desestacionalizadas más reciente. Las ecuaciones para calcular los valores de $\hat{\beta}_0$ y $\hat{\beta}_1$ son:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} t_i Y_i - \frac{\sum_{i=1}^{n} t_i \sum_{i=1}^{n} Y_i}{n}}{\sum_{i=1}^{n} t_i^2 - \frac{\left(\sum_{i=1}^{n} t_i\right)^2}{n}}$$

$$\hat{\beta}_0 = \overline{Y} - \hat{\beta}_1 \bar{t}$$

Donde

$$\overline{Y} = \frac{\sum_{1}^{n} Y_i}{n}, \text{ y } \bar{t} = \frac{\sum_{1}^{n} t_i}{n}$$

Observemos, sin embargo, que Y_t ahora se refiere al valor de la serie de tiempo desestacionalizada en el periodo t y no al valor real de la serie de tiempo. Con las relaciones dadas para $\hat{\beta}_0$ y $\hat{\beta}_1$ y los datos de ventas desestacionalizadas de la tabla 19, hacemos los cálculos siguientes:

	t	Y_t (desestacionalizado)	tY_t	t^2
	1	5.16	5.16	1
	2	4.88	9.76	4
	3	5.50	16.50	9
	4	5.70	22.80	16
	5	6.24	31.20	25
	6	6.19	37.14	36
	7	6.24	43.68	49
	8	6.49	51.92	64
	9	6.45	58.05	81
	10	6.67	66.70	100
	11	6.88	75.68	121
	12	6.84	82.08	144
	13	6.77	88.01	169
	14	7.02	98.28	196
	15	7.34	110.10	225
	16	7.37	117.92	256
Totales	136	101.74	914.98	1496

Tabla 20: Cálculos auxiliares para la proyección de la tendencia con valores desestacionalizados para las series de tiempo de las ventas de televisores

De la tabla 20 obtenemos que:

$$\bar{t} = \frac{136}{16} = 8.5$$

$$\bar{Y} = \frac{101.74}{16} = 6.359$$

$$\hat{\beta}_1 = \frac{914.98 - \frac{(136)(101.74)}{16}}{1496 - \frac{136^2}{16}} = 0.148$$

$$\hat{\beta}_0 = 6.359 - (0.148)(8.5) = 5.101$$

Por lo tanto:

$$T_t = 5.101 + 0.148t,$$

es la ecuación para el componente de tendencia lineal de la serie de tiempo.

La pendiente de 0.148 indica que durante los 16 trimestres anteriores la empresa ha experimentado un crecimiento desestacionalizado medio en las ventas de aproximadamente 148 televisores por trimestre. Si suponemos que la tendencia de los 16 trimestres pasados en datos de ventas es un indicador

razonablemente bueno del futuro, podemos utilizar esta ecuación para proyectar el componente de tendencia de la serie de tiempo para trimestres futuros. Por ejemplo, al sustituir $t = 17$ en la ecuación obtenemos la proyección de la tendencia del trimestre siguiente, T_{17}:

$$T_{17} = 5.101 + 0.148(17) = 7.617$$

De ahí que el componente de tendencia produzca un pronóstico de ventas de 7617 televisores para el trimestre siguiente. Del mismo modo, el componente de tendencia produce pronósticos de ventas de 7765, 7913 y 8061 televisores en los trimestres 18, 19 y 20, respectivamente.

2.5.6. Ajustes estacionales

El paso final en el desarrollo del pronóstico, cuando tanto el componente de tendencia como el estacional están presentes, es utilizar el índice estacional para ajustar la proyección de tendencia. Al retomar el ejemplo de las ventas de televisores, tenemos una proyección de tendencia para los cuatro trimestres siguientes. Ahora debemos ajustar el pronóstico para el efecto estacional. El índice estacional para el primer trimestre del año 5 $(t = 17)$ es 0.93, así que obtenemos el pronóstico trimestral al multiplicar el pronóstico con base en la tendencia $(T_{17} = 7617)$ por el índice estacional (0.93). Por tanto, el pronóstico para el trimestre siguiente es $7617(0.93) = 7084$. La tabla siguiente muestra el pronóstico trimestral para los trimestres 17-20. Los pronósticos muestran un cuarto trimestre con un alto volumen y un pronóstico de 9190 unidades, y un segundo trimestre con un bajo volumen y un pronóstico de 6523 unidades.

Año	Trimestre	Pronóstico de tendencia	Índice estacional (tabla 16.10)	Pronóstico trimestral
5	1	7617	0.93	(7617)(0.93) = 7084
	2	7765	0.84	(7765)(0.84) = 6523
	3	7913	1.09	(7913)(1.09) = 8625
	4	8061	1.14	(8061)(1.14) = 9190

Tabla 21: Pronósticos trimestrales para la serie de tiempo de ventas de televisores

Bibliografía

- Render, B., Stair, R., Hanna, M. & Osuna, M. (2012). *Métodos cuantitativos para los negocios*. México, D.F: Pearson Educación.

- Anderson, D., Sweeney, D. & Williams, T. (2011). *Métodos cuantitativos para los negocios (11a. ed*. México, D.F: CENGAGE Learning.

- Eppen, G., Ruiz, A. & García, G. (2000). *Investigación de operaciones en la ciencia administrativa : construcción de modelos para la toma de decisiones con hojas de cálculo electrónicas* . Naucalpan de Juárez , México: Prentice Hall.